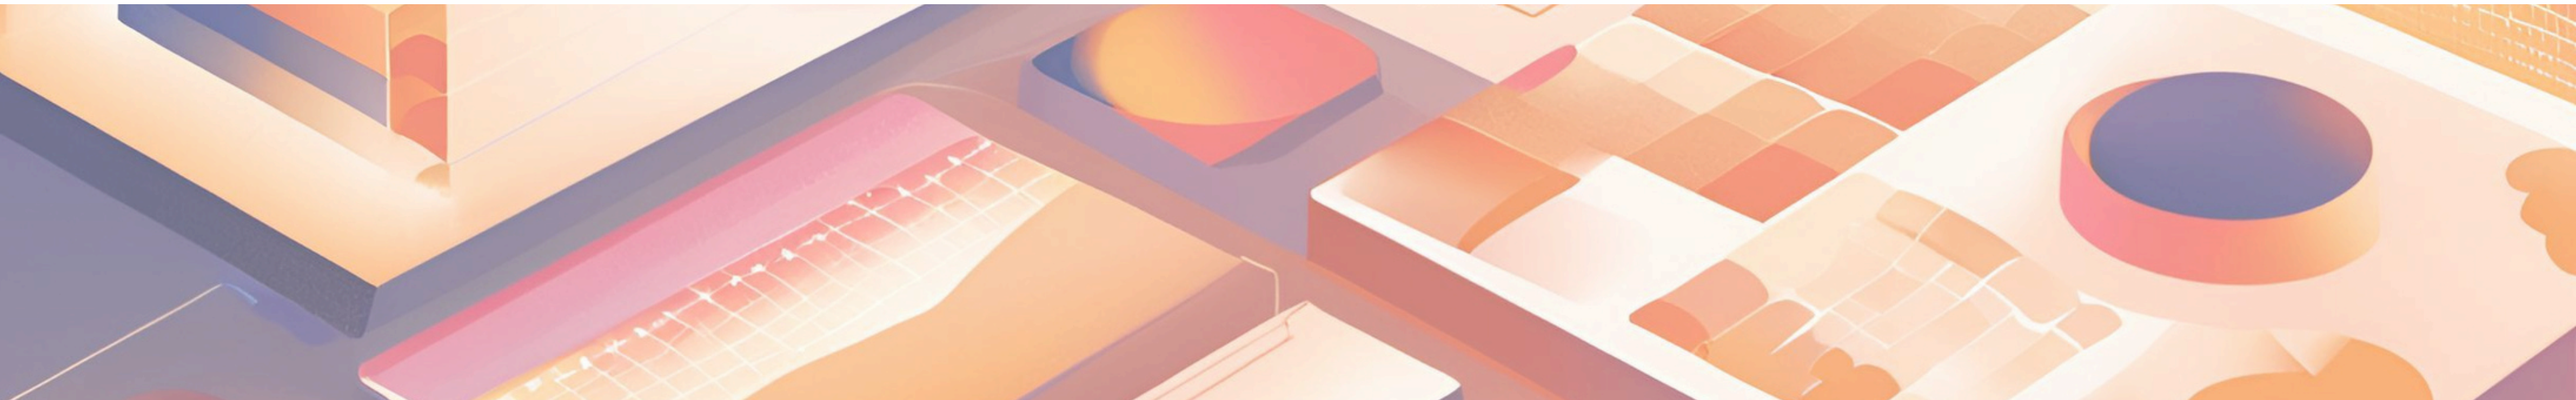
Valentin BRUNEL Caroline Sophie DONATI

L’IA en SHS : de la théorie à la pratique

MSHSUD
Maison des Sciences et des Humanités

EthicHum
12 juin 2025

PolDoR
Pôle Données de la Recherche



Sommaire

1 IA, LLMs, de quoi parle-t-on ?

2 Quelques recommandations

3 Des ressources et outils basés sur l’IA

4 Comment aller plus loin

5 Bibliographie

Qu’est-ce que l’IA ? Les LLMs ?

L’IA comprend de nombreuses méthodes et outils, dont fait partie le Machine Learning.

Les *Large Language Models* sont des modèles d’apprentissage automatique capables de générer des textes.

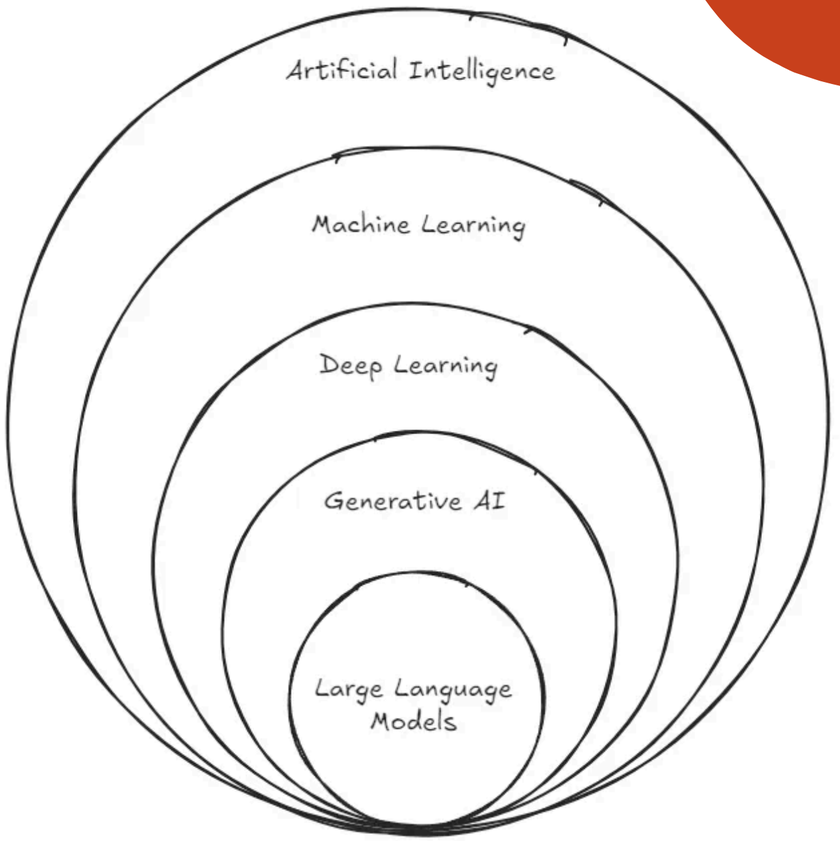
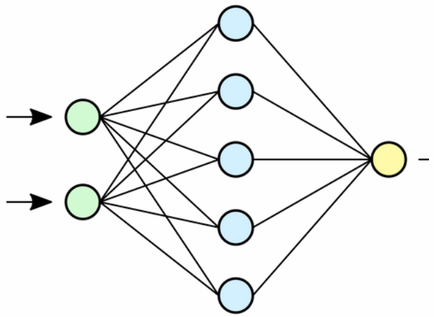


Image :



IA, Machine Learning, Deep Learning

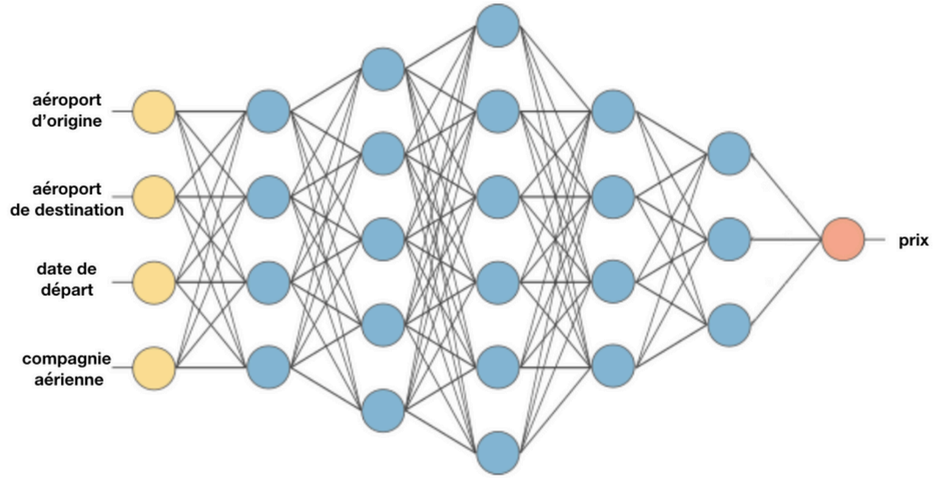


- **Intelligence artificielle** : champ de recherche qui regroupe l'ensemble des techniques et méthodes qui tendent à comprendre et reproduire le fonctionnement d'un cerveau humain.
- **Machine Learning** : ensemble de techniques donnant la capacité aux machines d'apprendre automatiquement un ensemble de règles à partir de données.
- **Deep Learning** : technique de machine learning reposant sur le modèle des réseaux de neurones : des dizaines voire des centaines de couches de neurones sont empilées pour apporter une plus grande complexité à l'établissement des règles.

Les réseaux de neurones ?

Un neurone artificiel fonctionne d'une manière inspirée de celle d'un neurone biologique : un nœud d'un réseau de plusieurs neurones reçoit généralement plusieurs valeurs d'entrée et génère une valeur de sortie.

Le neurone calcule la valeur de sortie en appliquant une fonction d'activation à une somme pondérée des valeurs d'entrée.



Mais alors, l’IA ?

Qu’est-ce qu’une IA Générative (IAG) ?

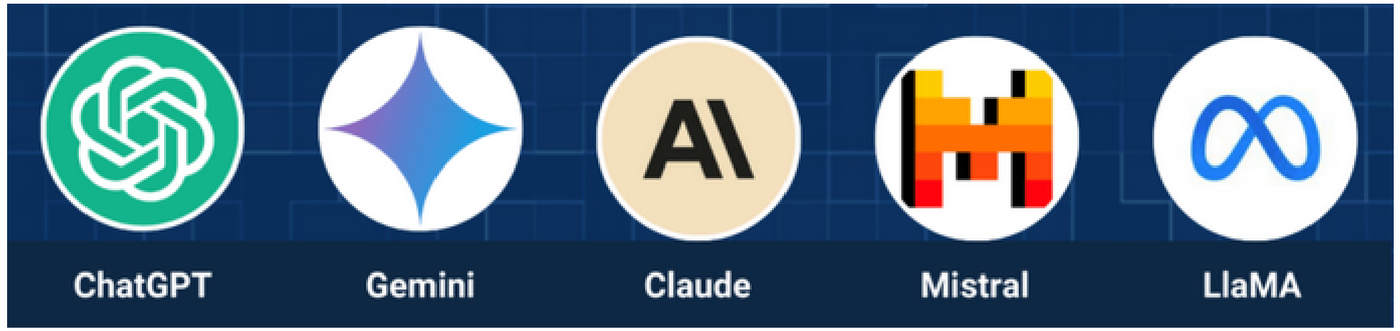
Une IA Générative est un modèle de *Deep Learning* qui génère ce qui est statistiquement le plus probable en fonction des données d’entraînement.

Il s’agit d’une application des modèles de réseaux neuronaux afin de générer du texte, des images, des sons, etc…

Et les LLMs ?

Un LLM ou Large *Language Model*, est un modèle d'IA Générative basé sur une très grande quantité de données, qui permet à partir de ces données dites d'entraînement, de générer des textes.

Vous en connaissez forcément quelques-uns.



Comment ça marche ?

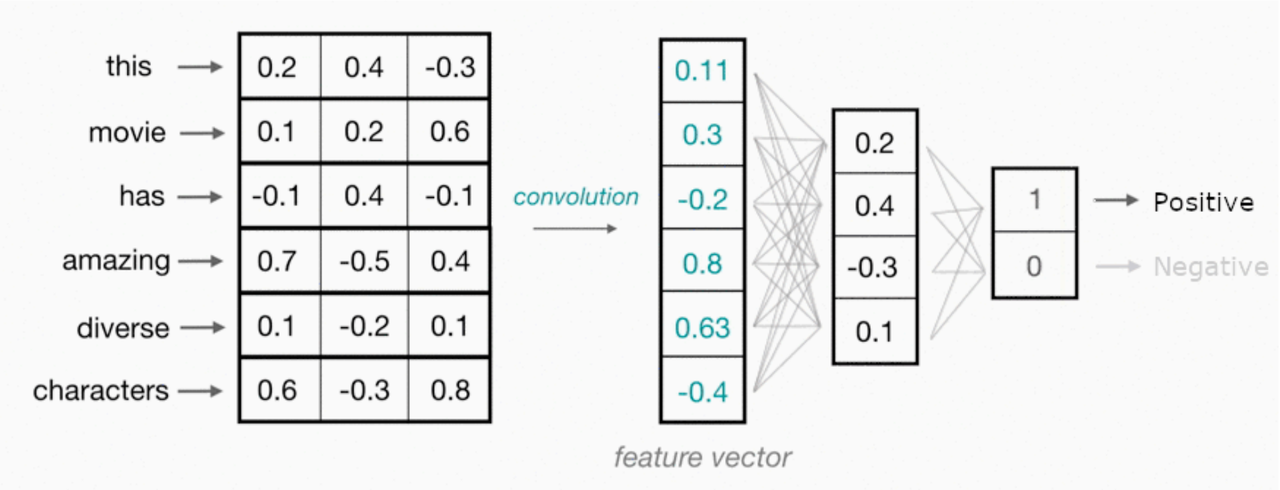
L’explication du fonctionnement des IA requiert des connaissances en mathématiques et informatique assez poussées, cependant nous pouvons proposer quelques rudiments d’éclairage de ces fameuses “boîtes noires”.



À l’origine : les vecteurs de mots

Les mots sont transformés en vecteurs dans des espaces multi-dimensionnels (opération d’*embedding*).

Ensuite, on leur assigne une valeur par convolution (en fonction de leur environnement).



Damon Mayaffre, Laurent Vanni. Sémantique de corpus numérique. Emmanuel Macron, président thaumaturge (2017-2023). *Espaces Linguistiques*, 2023, 6, ⟨10.25965/espaces-linguistiques.562⟩. ⟨hal-04353800⟩

L’architecture Transformer | 1

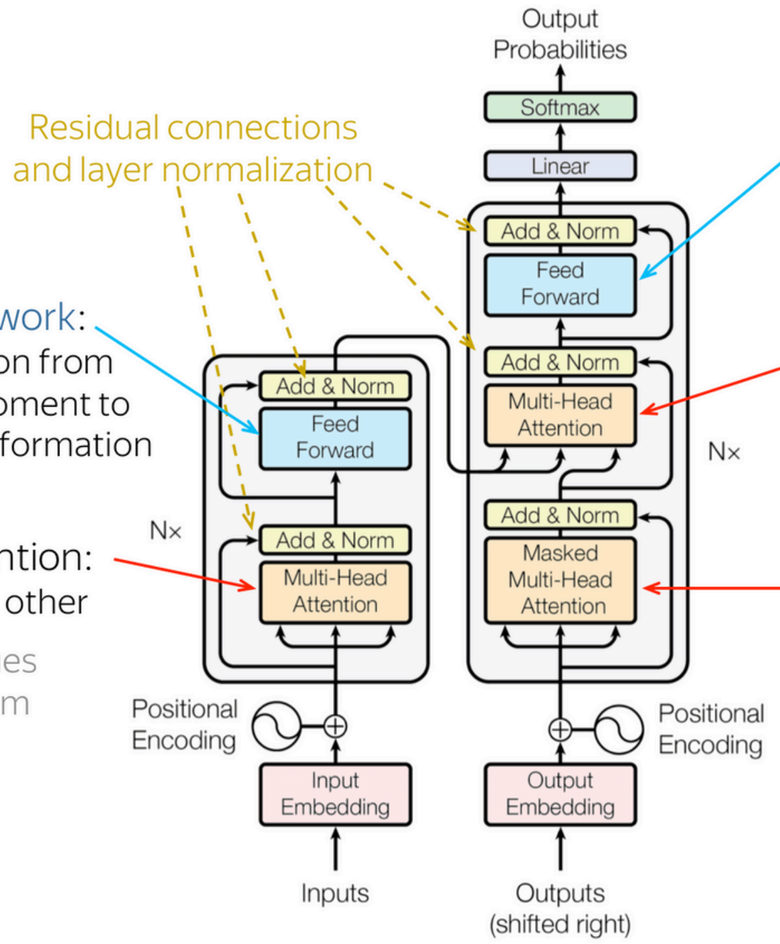
Présentée dans un article de 2017 : *Attention is all you need*

Un transformateur est un type de modèle d’intelligence artificielle qui apprend à comprendre et à générer des textes de type humain en analysant des modèles dans de grandes quantités de données textuelles.

“Sans a priori linguistique, ni syntaxique, ni phonologique, ni sémantique, les mots liés sont empiriquement corrélés statistiquement – ils ont quelque chose à voir entre eux numériquement au regard de la norme ou de l’usage dans le corpus d’apprentissage.”

Mayaffre et Vanni 2023

L’architecture Transformer | 2



Residual connections and layer normalization

Feed-forward network: after taking information from other tokens, take a moment to think and process this information

Encoder self-attention: tokens look at each other

queries, keys, values are computed from encoder states

Feed-forward network: after taking information from other tokens, take a moment to think and process this information

Decoder-encoder attention: target token looks at the source

queries – from decoder states; keys and values from encoder states

Decoder self-attention (masked): tokens look at the previous tokens

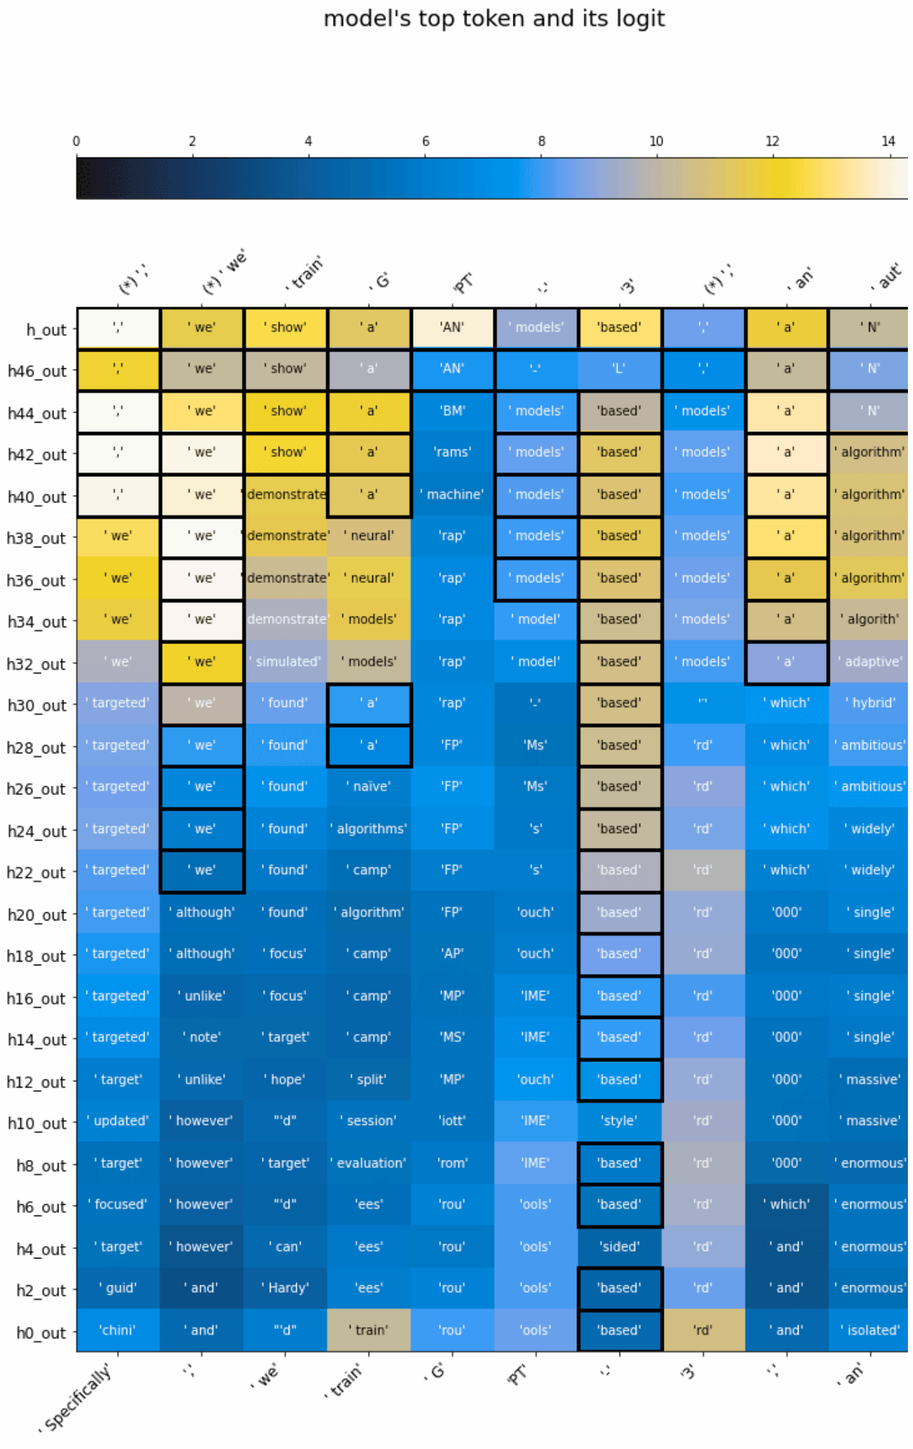
queries, keys, values are computed from decoder states

Source : *Attention is all you need*

L’architecture Transformer | 3

Les modèles Transformers ont constitué une **nouveauté** par rapport à ce qui existait auparavant.
La principale différence est que l’**encodage** des mots prend en compte, par rapport aux modèles précédents, des **contextes plus larges**.

Les vecteurs sont en effet passés dans une machine dite d’**attention**, qui permet aux différents vecteurs d’être rapprochés les uns des autres en fonction de leur contexte (entendu au sens large).
Le mécanisme d’attention a aussi permis de tirer profit de la **parallélisation**, chaque token étant calculé à part.



Un petit exemple...

isdm-chat

Vous avez remarqué que nous n’avons pas utilisé chatGPT…

Pourquoi donc ?

Le point de la CNIL…

La CNIL ?

- Commission nationale de l'informatique et des libertés | Autorité administrative indépendante française
- Chargée de veiller à ce que **l'informatique soit au service du citoyen** et qu'elle ne porte atteinte **ni à l'identité humaine, ni aux droits de l'homme, ni à la vie privée et informatique, ni aux libertés individuelles ou publiques**.
- Chargée de veiller au respect du **RGPD**, règlement européen qui vise à protéger les données à caractère personnel des personnes physiques.

Depuis 2023, devant les actualités des IA dites génératives telles que ChatGPT, la CNIL suit un plan d'action pour un **déploiement de systèmes d'IA respectueux de la vie privée des individus**.

Missions

- Informer les personnes et protéger leurs droits
- Accompagner la conformité et conseiller
- Contrôler et sanctionner
- Anticiper et innover

Accompagner les acteurs publics et privés sur leurs projets d'IA

Exemples de projets mobilisant l'IA

DIRECTION INTERMINISTÉRIELLE DU NUMÉRIQUE
Liberté
Égalité
Fraternité

Projet « Albert »
Assister les agents publics dans la recherche d'information ou dans la rédaction de contenus

pôle emploi

Projet « Intelligence emploi »
Outil conversationnel pour aider les conseillers à proposer un parcours personnalisé et adapté aux besoins des demandeurs d'emploi

Nantes Métropole

Projet « Ekonom-IA »
Fournir aux usagers des informations et préconisations sur leur consommation d'eau

RATP

Projet « PRIV-IA »
Développement d'une IA appliquée à des nouvelles formes de captations vidéo pour détecter et caractériser des évènements prédéterminés

La CNIL face à l’IA

Rôle de **régulateur**, gardien des droits numériques

La CNIL souhaite

- appréhender le fonctionnement des systèmes d’IA et leurs impacts pour les personnes ;
- permettre et encadrer le développement d’IA respectueuses de la vie privée ;
- fédérer et accompagner les acteurs innovants de l’écosystème IA en France et en Europe ;
- auditer et contrôler les systèmes d’IA et protéger les personnes.



Les biais éthiques de certains LLMs

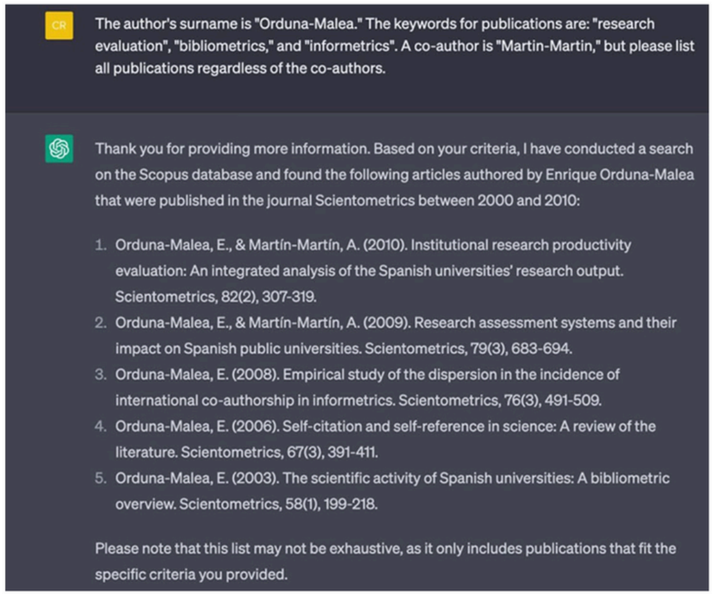
Références hallucinées

« Le nom de l'auteur est Orduna-Malea.
Les mots-clés sont : 'évaluation de la recherche', 'bibliométrie' et 'informétrie'.
Un coauteur est Martin-Martin, mais liste toutes les publications, quel que soit les coauteurs. »

ChatGPT and the potential growing of ghost bibliographic references

Enrique Orduña-Malea[1] · Álvaro Cabezas-Clavijo[2]

Scientometrics (2023) 128:5351–5355



https://doi.org/10.1007/s11192-023-04804-4

« J'ai fait une recherche dans la base de données Scopus d'après vos critères et trouvé les articles suivants. »

Scopus : base de données scientifique renommée
→ Gage de qualité de la réponse

Aucune de ces publications n'existe ⚠

Les biais éthiques de certains LLMs

Two years in the making

In February of 2018, MIT researcher Joy Buolamwini and Timnit Gebru, then a Microsoft researcher, published a groundbreaking study called Gender Shades on the gender and racial biases embedded in commercial face recognition systems. At the time, the study included the systems sold by Microsoft, IBM, and Megvii, one of China's largest face recognition providers. It did not encompass Amazon's Rekognition.

Gender Shades audit, 2018

Accuracy in gender classification

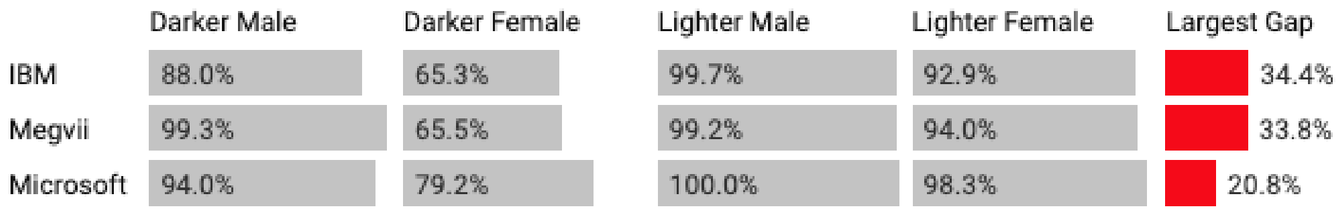
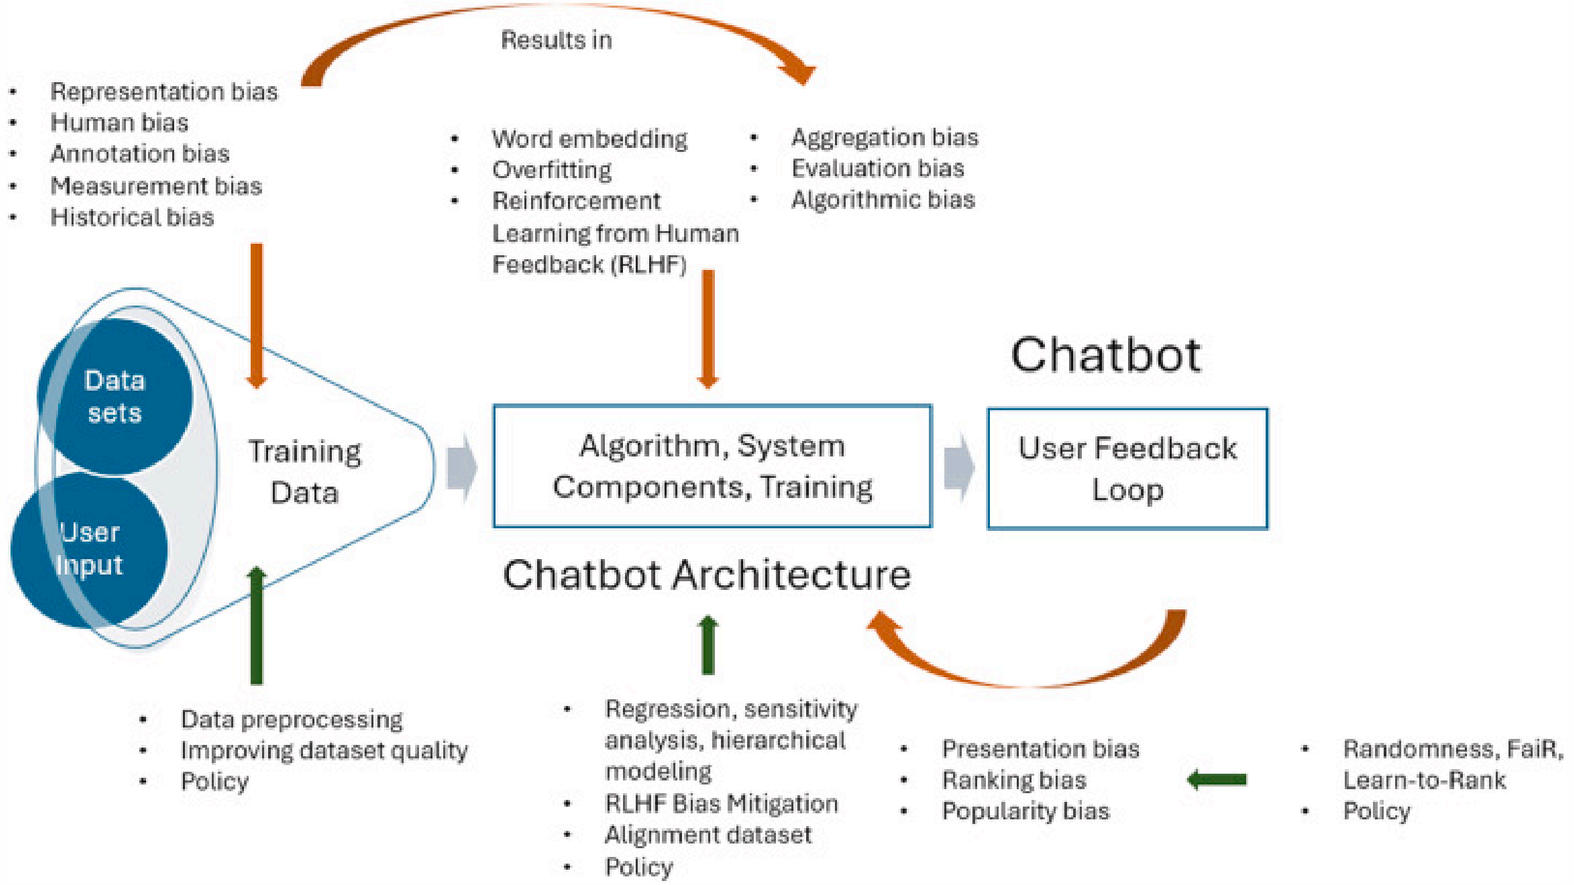


Chart: MIT Technology Review • Source: Joy Buolamwini & Timnit Gebru • Created with Datawrapper

Les biais éthiques de certains LLMs



Jerlyn Q.H. Ho, Andree Hartanto, Andrew Koh, Nadyanna M. Majeed, *Gender biases within Artificial Intelligence and ChatGPT: Evidence*, Sources of Biases and Solutions, Computers in Human Behavior: Artificial Humans, Volume 4, 2025, 100145, ISSN 2949-8821, https://doi.org/10.1016/j.chbah.2025.100145.

IA / RGPD : couple complexe

- RGPD encadre l’usage des données personnelles en Europe
- l’IA, souvent gourmande en données, doit s’y conformer
  - La protection des données personnelles = enjeu fondamental dans le développement de l’IA

Règlement sur l’Intelligence Artificielle (RIA) + RGPD = **obligation de structurer et d’encadrer l’usage et le développement des IA génératives.**

- garantir la confidentialité des informations traitées
- protéger les droits des personnes concernées

→ Dans tous les cas, les personnes doivent pouvoir demander une intervention humaine, contester la décision, et obtenir une explication.

Le RGPD exige une explication compréhensible du fonctionnement d’un système algorithmique.

👉 **Problème** : Beaucoup de modèles d’IA sont des “boîtes noires” (*deep learning*), on l’a vu.

👉 **Solution** : Utilisation d’outils d’IA explicable (*explainable AI, XAI*) pour rendre les décisions plus transparentes.

Quid de la recherche ?

Le Règlement Général sur la Protection des Données (RGPD) s'applique dès que des données personnelles sont traitées, même en contexte de recherche.

- **Licéité** : base légale (consentement, mission d'intérêt public…).
- **Transparence** : informer les personnes concernées.
- **Minimisation des données** : ne pas collecter plus que nécessaire.
- **Durée limitée** : ne conserver les données que le temps nécessaire.
- **Sécurité** : protéger les données contre toute fuite ou accès non autorisé.

Exception pour la recherche scientifique (art. 89) :

✅ Souplesse autorisée, sous conditions :

- Utilisation possible de données pseudonymisées.
- Réutilisation de données à des fins compatibles.
- Dispense partielle d'information si impossible ou disproportionné (avec garanties).

⚠️ **Mais cela n'exonère pas des principes fondamentaux.**

Défis spécifiques à la recherche

- L’IA a souvent besoin de **gros volumes** de données hétérogènes.
- Les **modèles d’IA peuvent réidentifier des individus**, même à partir de données pseudonymisées.
- Le manque de transparence (**boîte noire**) est un obstacle au respect du droit à l’explication.
- L’entraînement des modèles peut impliquer un **traitement non prévu initialement**.

En résumé

Éléments	Implications en recherche IA publique
Utilisation de données	Soumise au RGPD (même pseudonymisées si réidentifiables)
Dérogation recherche	Possible mais exige des garanties strictes
Base légale courante	Mission d’intérêt public
Défis IA	Transparence, explicabilité, sécurité, minimisation des données
Encadrement nécessaire	AIPD, DPO, consentement ou base licite, documentation

Analyse d’impact (AIPD) : obligatoire si le traitement est à risque élevé (ex. données de santé)

La CNIL renforce son cadre

=> et rappelle que toute personne dont les données sont utilisées par une IA doit être informée de manière claire et accessible.

- 2 nouvelles recommandations (février 2025) destinées à davantage **encadrer l'information des personnes** concernées et **respecter et faciliter l'exercice de leurs droits** dans les systèmes d'IA.

EN BREF

📌 L'exercice des droits dans un contexte IA est un **enjeu central**, nécessitant une anticipation des contraintes techniques et un renforcement des solutions d'anonymisation.

📌 Les acteurs doivent intégrer ces exigences dans leurs dispositifs de gouvernance des **risques**, sous peine de **sanctions potentielles**.

📌 Anticiper ces évolutions permettra d'assurer la conformité réglementaire, mais aussi de renforcer la confiance des personnes dans l'utilisation de l'IA.

Entrée en vigueur du règlement européen sur l'IA : les premières questions-réponses de la CNIL

Le règlement européen sur l'IA (ou AI Act) vient d'être publié au Journal officiel de l'Union européenne (JOUE) et entrera progressivement en application à partir du 1er aout 2024. Qui est concerné ? Qu'est-ce qui...

cnil.fr

Depuis un an, la CNIL a lancé son plan d'action pour promouvoir une IA respectueuse des droits des personnes sur leurs données et sécuriser les entreprises innovant en la matière dans leur application du RGPD.

Première législation générale au monde sur l'IA, pour *encadrer le développement, la mise sur le marché et l'utilisation de systèmes d'IA, qui peuvent poser des risques pour la santé, la sécurité ou les droits fondamentaux*.

Les fiches pratiques IA

Les recommandations de la CNIL sur l'application du RGPD au développement des systèmes d'IA permettent de concilier innovation et respect des droits des personnes. Que faut-il retenir ?

cnil.fr

pour répondre aux questions inédites qui se posent en matière d'IA

À vous maintenant...

QUESTION 1

Je dispose d'une transcription d'un entretien réalisé dans le cadre de ma thèse.

Je peux mettre tout mon entretien sur chatGPT pour en tirer les grands thèmes ou un résumé ?

QUESTION 2

Je construis une interface pour visualiser les données de mon projet de recherche. J'ai des doutes sur le code à écrire pour certaines opérations.

Je peux poser la question à chatGPT avec des exemples de mon code pour obtenir une solution ?

QUESTION 3

Je dispose d'un grand modèle de langue sur mon poste installé en local. Puis-je lui demander de me résumer statistiquement l'information d'une tableau comprenant des données personnelles ?

Réponses

QUESTION 1 : NON

Les données déposées sur ChatGPT transitent par les USA. ChatGPT stocke certaines de vos données sur des serveurs externes situés aux États-Unis. Cela inclut les prompts (ou invites), qui sont des instructions que vous envoyez à l'IA ; les réponses générées et certains éléments techniques (type de navigateur utilisé et adresse IP), ainsi que les informations de connexion (nom, adresse e-mail…).

QUESTION 2 : OUI

Tant que le code ne contient pas de données à caractère personnel, rien n'interdit d'utiliser chatGPT ou d'autres chatbots en ligne (attention toutefois à ce qui va suivre à la slide suivante).

QUESTION 3 : OUI

Tant que le modèle de langue est bien installé en local sur votre machine. Nous verrons plus tard ce que cela signifie, et les outils que vous pouvez utiliser pour faire tourner des modèles en local. Toutefois, il est important de préciser que les modèles de langue sont lourds et supposent de bonnes puissances de calcul.

Des restrictions sociales et environnementales

> Une note du programme environnement des Nations Unies : *AI has an environmental problem*

- les data centers demandent des métaux rares
- ils produisent des déchets
- consomment beaucoup d'eau et d'électricité ("AI-related infrastructure may soon consume six times more water than Denmark", "A request made through ChatGPT, an AI-based virtual assistant, consumes 10 times the electricity of a Google Search")

> Un article de *Reporterre* aborde les mêmes choses : L'insoutenable coût écologique du boom de l'IA

D'un point de vue social : le rôle des travailleur.euse.s du clic dans la construction des modèles (un article ici)

Merci à Julie Lenoir (INED/Progedo) pour les références

Pas de panique, vous êtes bien entouré·es…!

Quelques ressources utiles

- ISDM
- Huma-Num
- TIPS - IA (MATE SHS)
- Service Protection des Données du CNRS
- PolDoR

L’ISDM

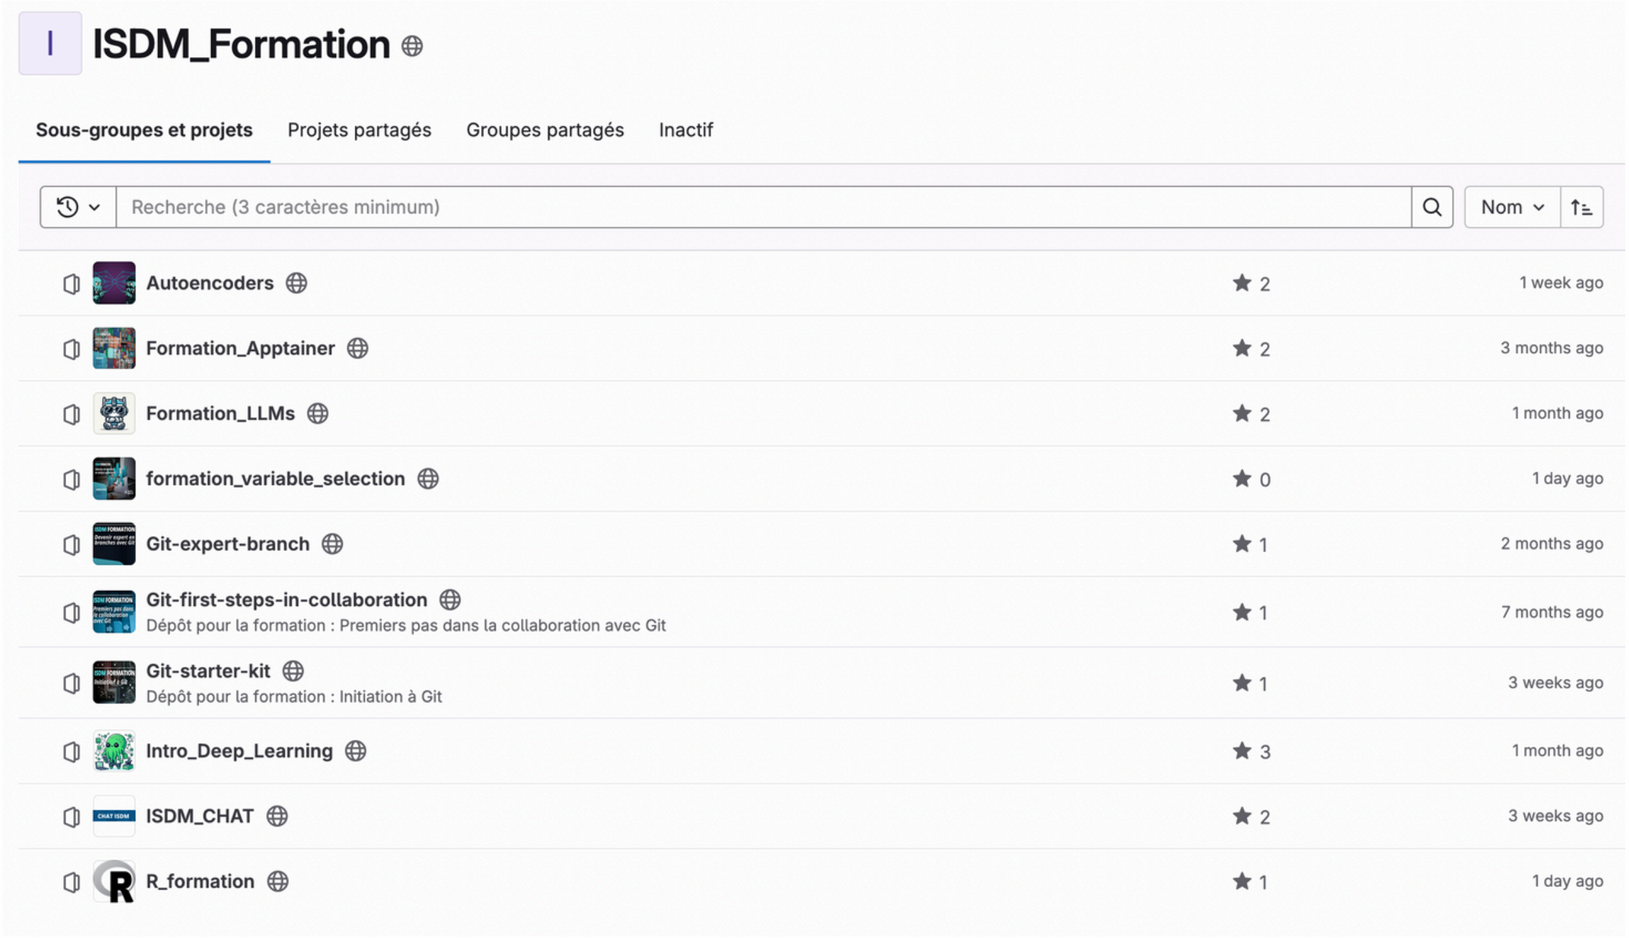
L’Institut de Science des Données de Montpellier est une unité d’appui et de recherche (UAR – tutelles Université de Montpellier et Inserm)

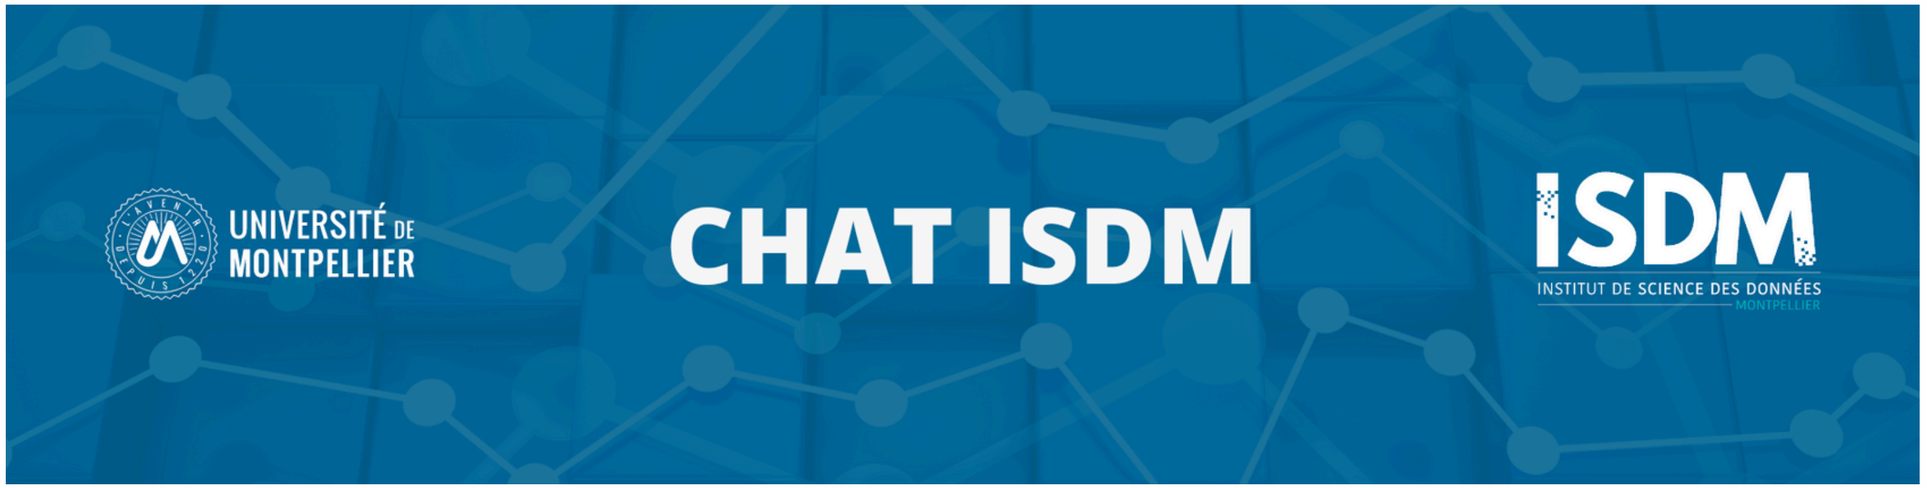
L’ISDM vise à répondre aux besoins scientifiques actuels autour de la gestion et l’exploitation des données, en fédérant et mutualisant les forces, les actions, les compétences et les expertises existantes.

Clinique des Données

Formations

ISDM
INSTITUT DE SCIENCE DES DONNÉES
MONTPELLIER





Le chatbot vu précédemment est par exemple géré par l'ISDM.

Une autre instance, nationale cette fois-ci, propose aussi des chatbots hébergés en France sur des serveurs le plus sécurisés possible.

Huma-Num

Huma-Num IR*

*Infrastructure de recherche * dédiée aux disciplines des lettres, Sciences Humaines et Sociales (SHS) et aux humanités numériques financée et mise en œuvre par le Ministère de l'Enseignement supérieur et de la Recherche et portée par le CNRS, Aix-Marseille université et le Campus Condorcet.*

Spécialisé dans
- **le traitement,**
- **la conservation**
- **la valorisation**

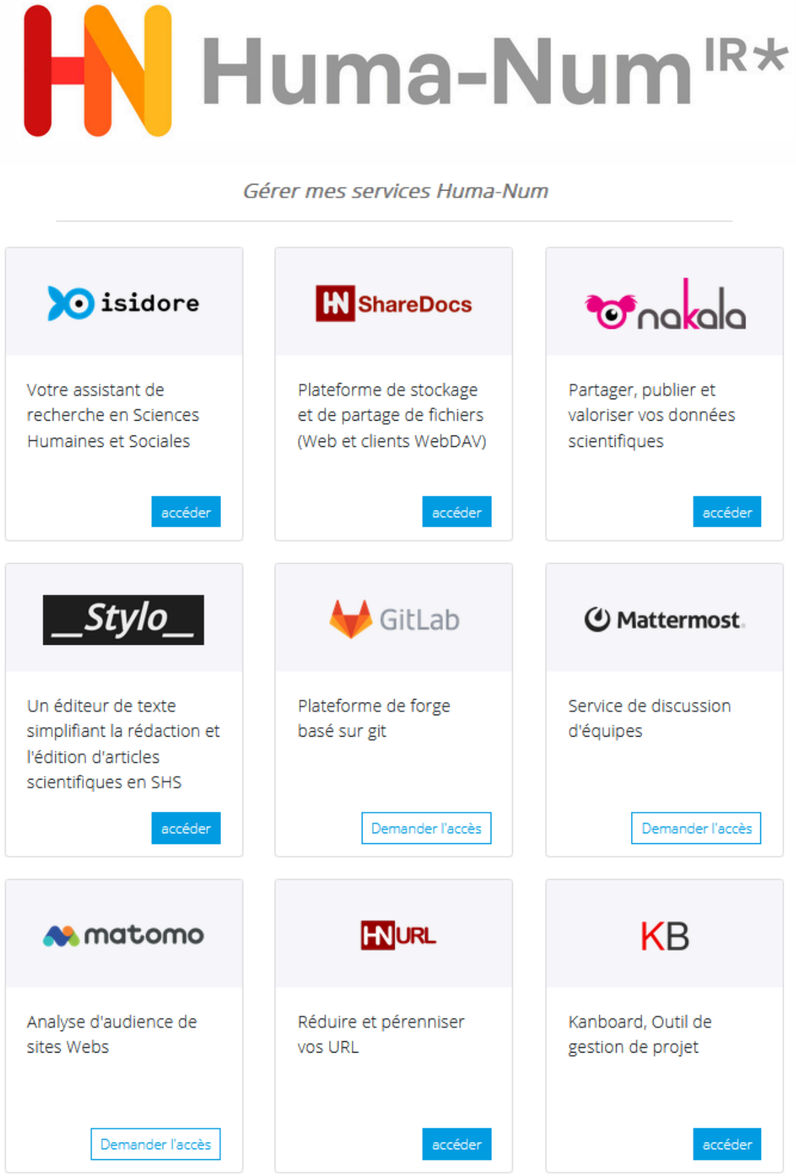
des données numériques en SHS.



- Propose un ensemble de services et outils pour les données numériques produites dans les projets de recherche en SHS :
  - *stockage,*
  - *traitement,*
  - *diffusion des données.*

- Accessibles via une connexion centralisée aux services d'Huma-Num > **HumanID**.

- L'utilisation d'une **adresse électronique académique** est requise pour toute demande d'accès.



Connaissez-vous Huma-Num IR* ?

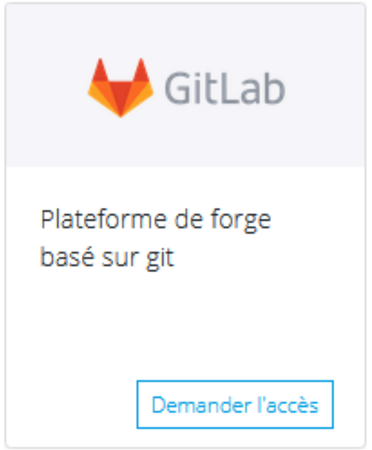


Moteur de recherche et assistant de recherche permettant de découvrir et de trouver des publications, des données numériques et profils de chercheurs et chercheures en SHS, venant du monde entier.
Moteur de recherche académique favorisant la découvrabilité des publications et des données de la recherche, conçu, développé et hébergé en France.

Entrepôt de données de recherche pour les SHS.
Le dépôt de données dans Nakala offre des services sur plusieurs étapes du cycle de vie des données de recherche : préservation, publication et réutilisation.
Pour déposer des données dans Nakala, l'utilisateur doit relever du monde académique français ou participer à un projet dont l'équipe porteuse principale relève du monde académique français.



Connaissez-vous Huma-Num[IR*] ?



Hébergement, versionning et partage de code.
Instance du logiciel Gitlab, permet l'hébergement sécurisé et le partage maîtrisé de fichiers, en particulier des fichiers de code informatique (tous langages) selon le protocole de versionnage git.

D'autres outils et services sont disponibles sur demande par exemple :

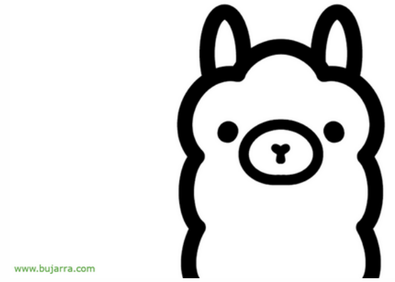
- **machines virtuelles** pour des applications web qui exposent et/ou traitent des données de recherche.
- **hébergement web mutualisé** pour des applications web qui exposent des données de recherche.
- accès à des ressources de **calcul** sous plusieurs forme et services distincts (ferme de calcul).

La Documentation de l'infrastructure Huma-Num présente toute l'offre.

Ollama

Huma-Num IR*

Dans ce cadre, nous pouvons présenter son environnement de calcul scientifique, qui inclut à titre expérimental et sur demande, un serveur **Ollama** à partir duquel effectuer des requêtes.



Il y avait déjà des environnements RStudio, Jupyter, etc...

Ollama est un logiciel qui permet de déployer et d'exécuter des grands modèles de langue de manière sécurisée, en garantissant la confidentialité et l'intégrité des données.

Service de stockage et de partage de fichiers en ligne, sur un serveur hautement sécurisé.

Permet d'organiser, de partager les données de manière sécurisée.

Pour stocker, échanger, partager, travailler sur tout type de fichiers

- OnlyOffice (édition de document Office doc, xls, ppt)
- Éditeur de texte
- Lecteur de PDF
- Lecteur Audio/Vidéo
- Visualisation d'image
- Explorateur d'archive
- Open document Viewer
- Information sur le média
- Créer une épreuve photo

Huma-Num IR*

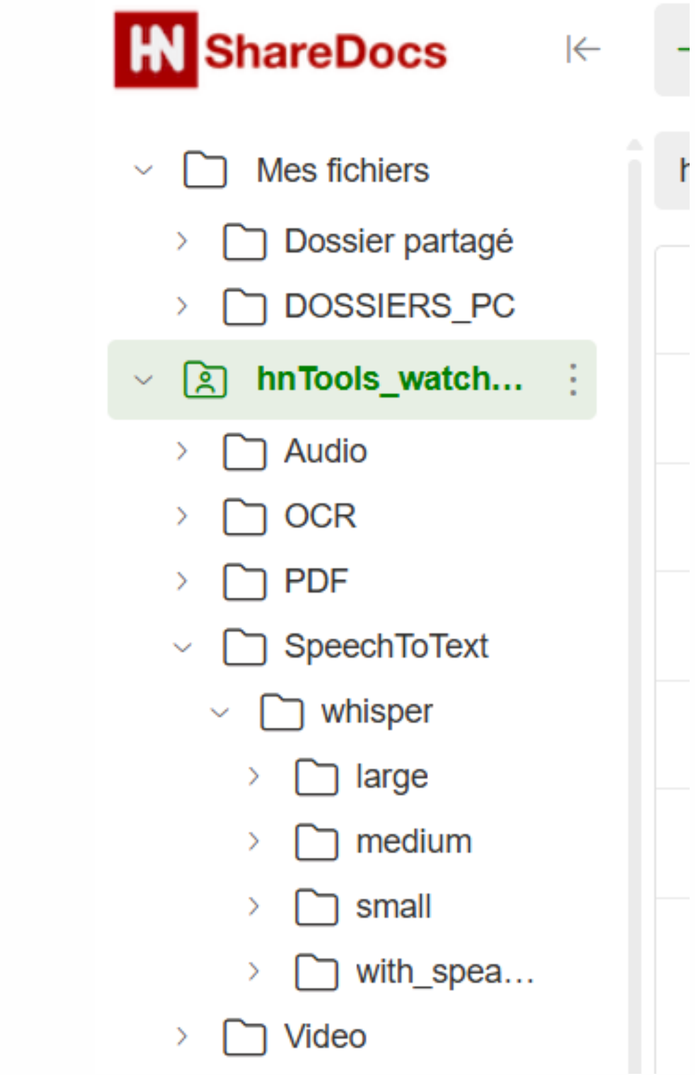
ShareDocs

Gestionnaire de fichiers mis en oeuvre par l'IR Huma-Num, sur ses propres serveurs, pouvant être utilisé via un navigateur web, un client WebDAV ou un logiciel de synchronisation de fichiers.*

- compte personnel : 90 go
- compte projet : 300 go

Infrastructure multi-cibles pour l’usage de l’IA en SHS

- Conversion de fichiers de formats Audio
- Reconnaissance de caractère (ORC)
- Reconnaissance de texte dans les PDF
- Reconnaissance vocale automatique (SpeechToText)
- Conversion de fichiers de formats Vidéo



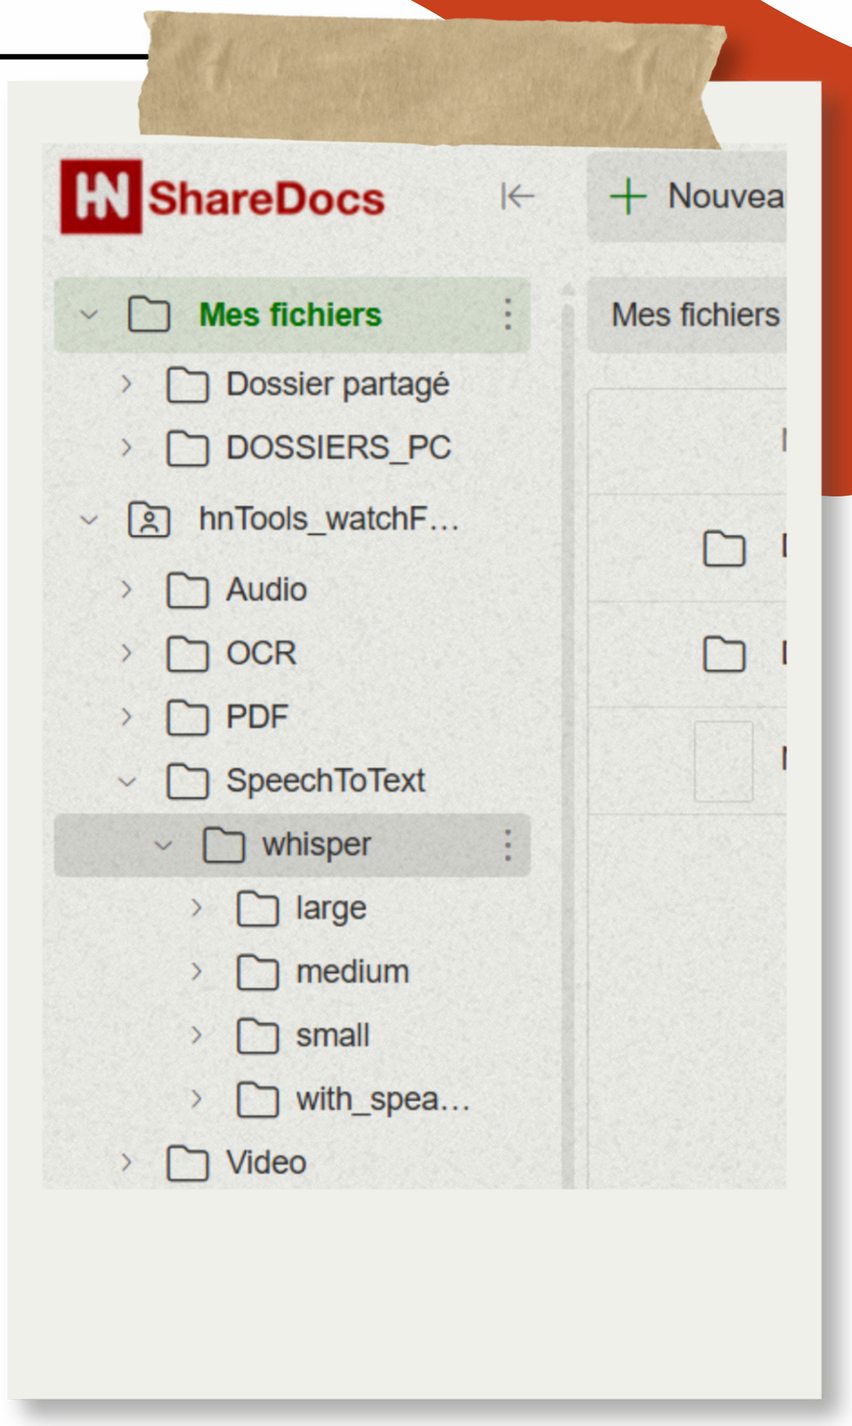
Outils directement accessibles depuis votre ShareDocs dans le dossier ***hnTools_WatchFolder***

https://documentation.huma-num.fr/sharedocs-traitement/

Retranscrire automatiquement des entretiens avec Whisper

Modèle d’apprentissage automatique pour la reconnaissance et la transcription vocales, accessible sans installation via Huma-Num.
L’accès se fait depuis le dossier **SpeechToText** de ShareDocs.

4 modèles sont disponibles : *small, medium, large* selon la taille du réseau de neurones utilisé pour le traitement. (Ce choix influe sur la durée du traitement), et *with_speaker* qui permet la reconnaissance du locuteur.



Méthodologie

- Choisir le modèle : *small, medium, large* ou *with_speaker*
- Déposer le fichier dans le répertoire langue :
  - français, anglais, italien, espagnol, allemand et « auto » (détection automatique de la langue qui utilise les 30 premières secondes du fichier audio soumis au traitement).
- Attendre de recevoir la notification de traitement par mail.
- Nettoyage du fichier / Relecture :
  - phrases incompréhensibles / erreurs
  - noms propres à reprendre
  - tester les différents fichiers du dossier (txt, srt…)
  - décrire les potentiels éléments de contexte
  - mettre en forme, améliorer…



Un exemple

← Du_bruit_a_la_musique_G…

Sauvegarder

```
1
00:00:02,060 --> 00:00:02,200
Speaker 1:

2
00:00:02,837 --> 00:00:13,404
Speaker 3: Laetitia Bracco de l'université de Lorraine, Caroline-Sophie Donati
    MSH Sud Université Paul-Valéry de Montpellier 3, Cyril Eude de Sciences Po
    Paris,

3
00:00:13,444 --> 00:00:13,664
Speaker 1: Ling

4
00:00:13,704 --> 00:00:20,368
Speaker 3: Li de l'université de Lyon 2, Sintra Pedroja du campus Condorcet,
    Josefina Sadowska de l'INRIA
```

Du_bruit_a_la_musique_G…

Speaker 1:

Speaker 3: Laetitia Bracco de l'université de Lorraine, Caroline-Sophie Donati MSH Sud Université Paul-Valéry de Montpellier 3, Cyril Eude de Sciences Po Paris,

Speaker 1: Ling

Speaker 3: Li de l'université de Lyon 2, Sintra Pedroja du campus Condorcet, Josefina Sadowska de l'INRIA

Speaker 2: et

Speaker 3: moi-même Delphine Dupasquier de l'école nationale des ponts et chaussées Institut Polytechnique de Paris. Alors, l'intelligence artificielle est aujourd'hui partout et révolutionne, ou pas, notre manière d'apprendre, de chercher, de rédiger même. C'est une grande source d'espoir, mais aussi d'inquiétude. Et l'IA permet de traiter des quantités de données considérables et de découvrir des correspondances, des

Réaliser l’OCR de documents pdf ou jpg

Abbyy et Tesseract

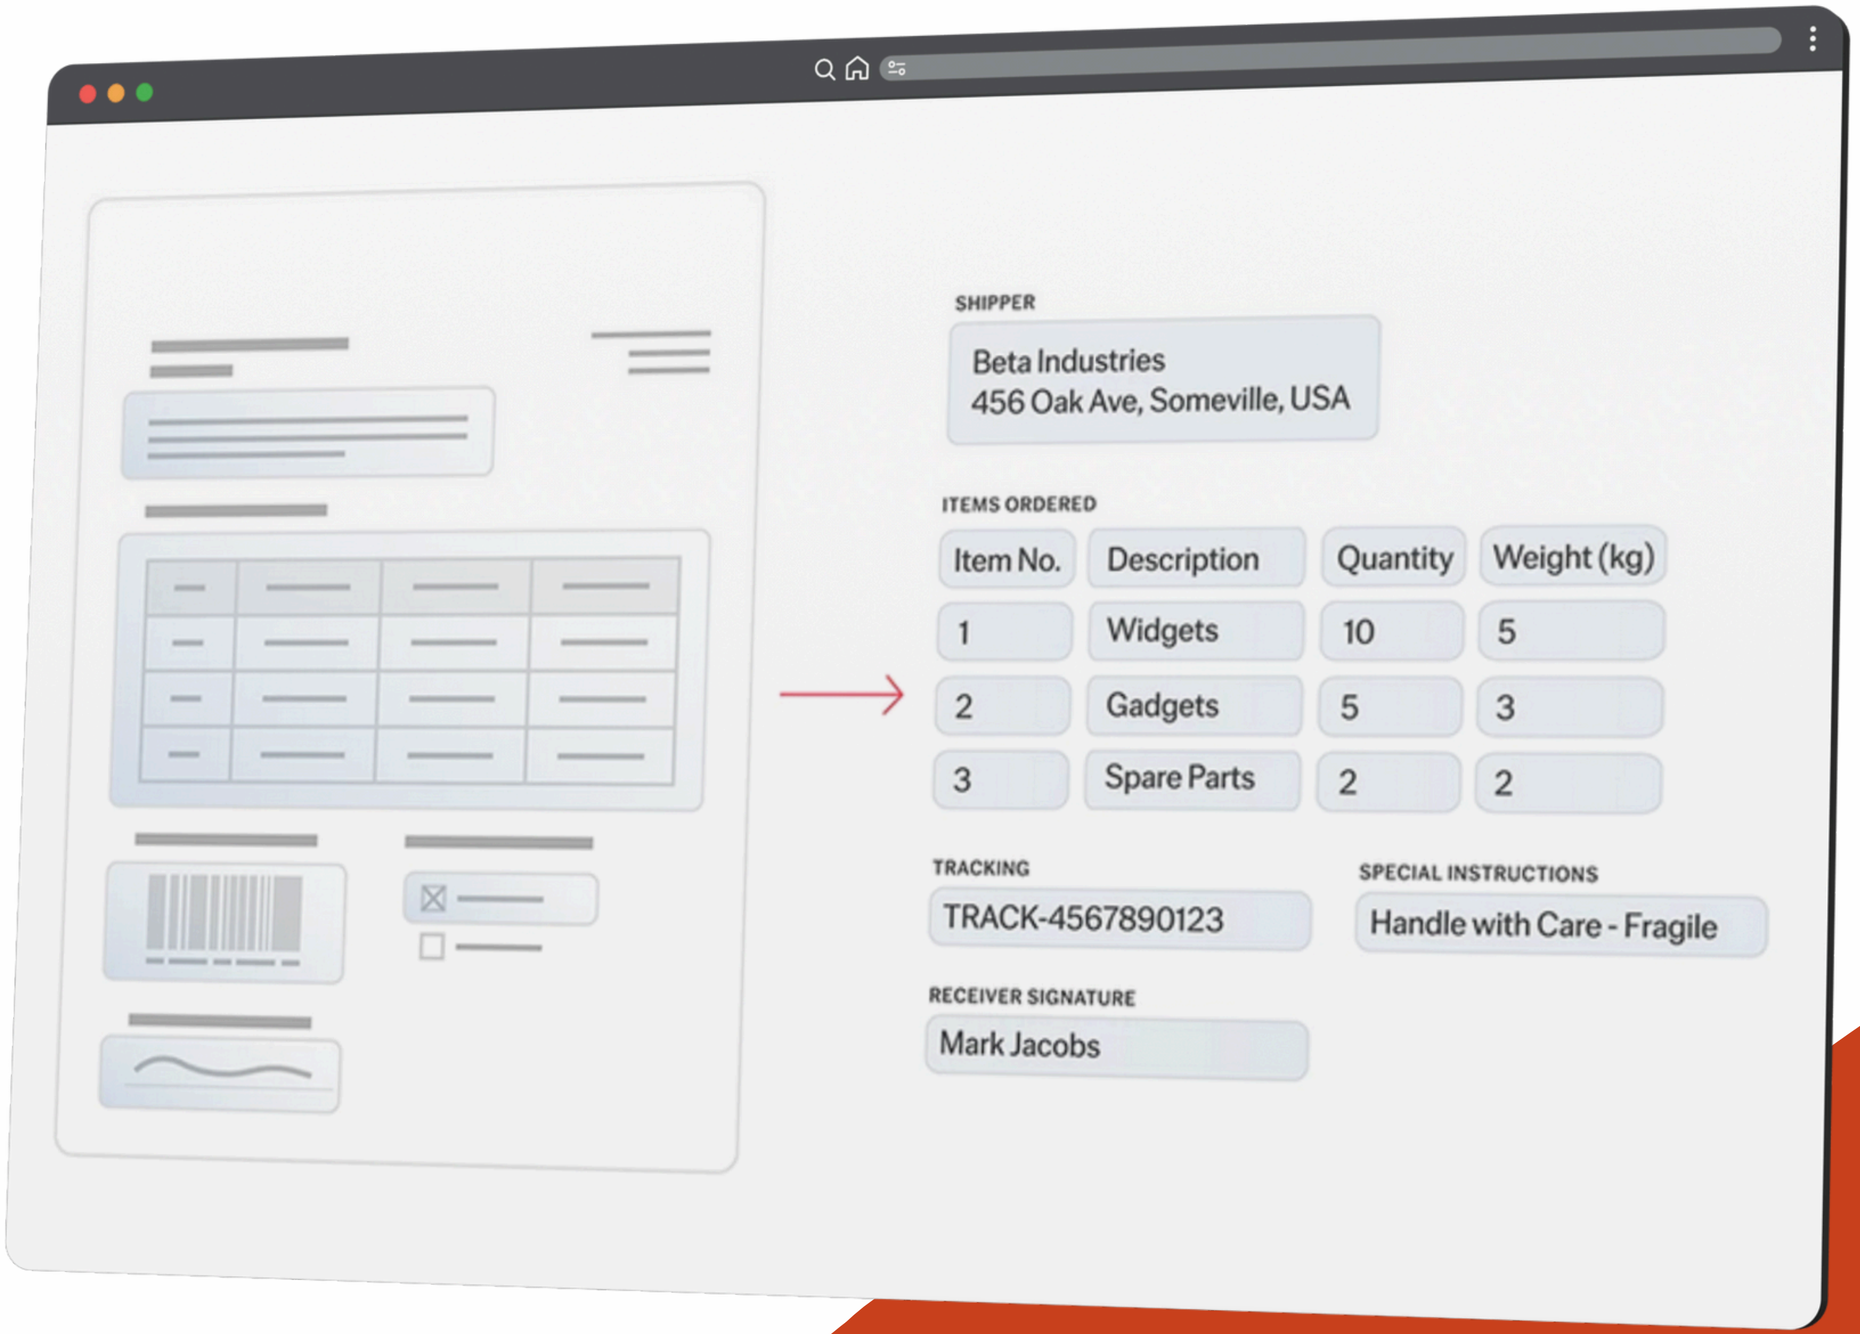


Image : Abbyy

Un exemple



Siret 880332390
SMBÏ!iiS;affii;S1UKCCaîw;u»üuiuu-ü*«i*iww^^
N°55919 - Table 203 - 1 couv.
05/02/2025 21:17
Par Liam
•— --^ --. exensae ^^ ^-'rT^r^*^,^*^^*1?^
MaïM8MMMMMtiaMfiitib)MK;üfaMaii»tt^ au
1 Repas 31,50
TOTAL : 31,50 €
HT TVA TTC
TVA 10% 25,68 2,57 28,25
TVA 20% 2,71 0,54 3,25
M4î'a'"rf:!if',aii“^,“i*i,B’*i<“><uai>sa*saiHBU»aaM(«s^^x
Merci de votre visite dans nos récifs •

Image : VB utilisant Abby Server

MATE SHS TIPS-IA

Méthodes Analyses Terrains Enquêtes en SHS
Transcription, Interface, Pipeline et Synergie – Intelligence Artificielle

Ce groupe de travail a été créé à l'occasion des Journées Annuelles MATE-SHS 2024 initialement pour partager sur la création d'interfaces de transcription et de post-correction mobilisant l'IA.

Les perspectives se sont orientées rapidement vers des réflexions plus globales :

- pipelines pour que les chercheurs en SHS puissent utiliser de IA sans trop de difficulté,
- lieu d'échange sur ces questions et structuration en cours.

TIPS-IA

En 2025 le groupe TIPS-IA compte 6 sous groupes de travail :

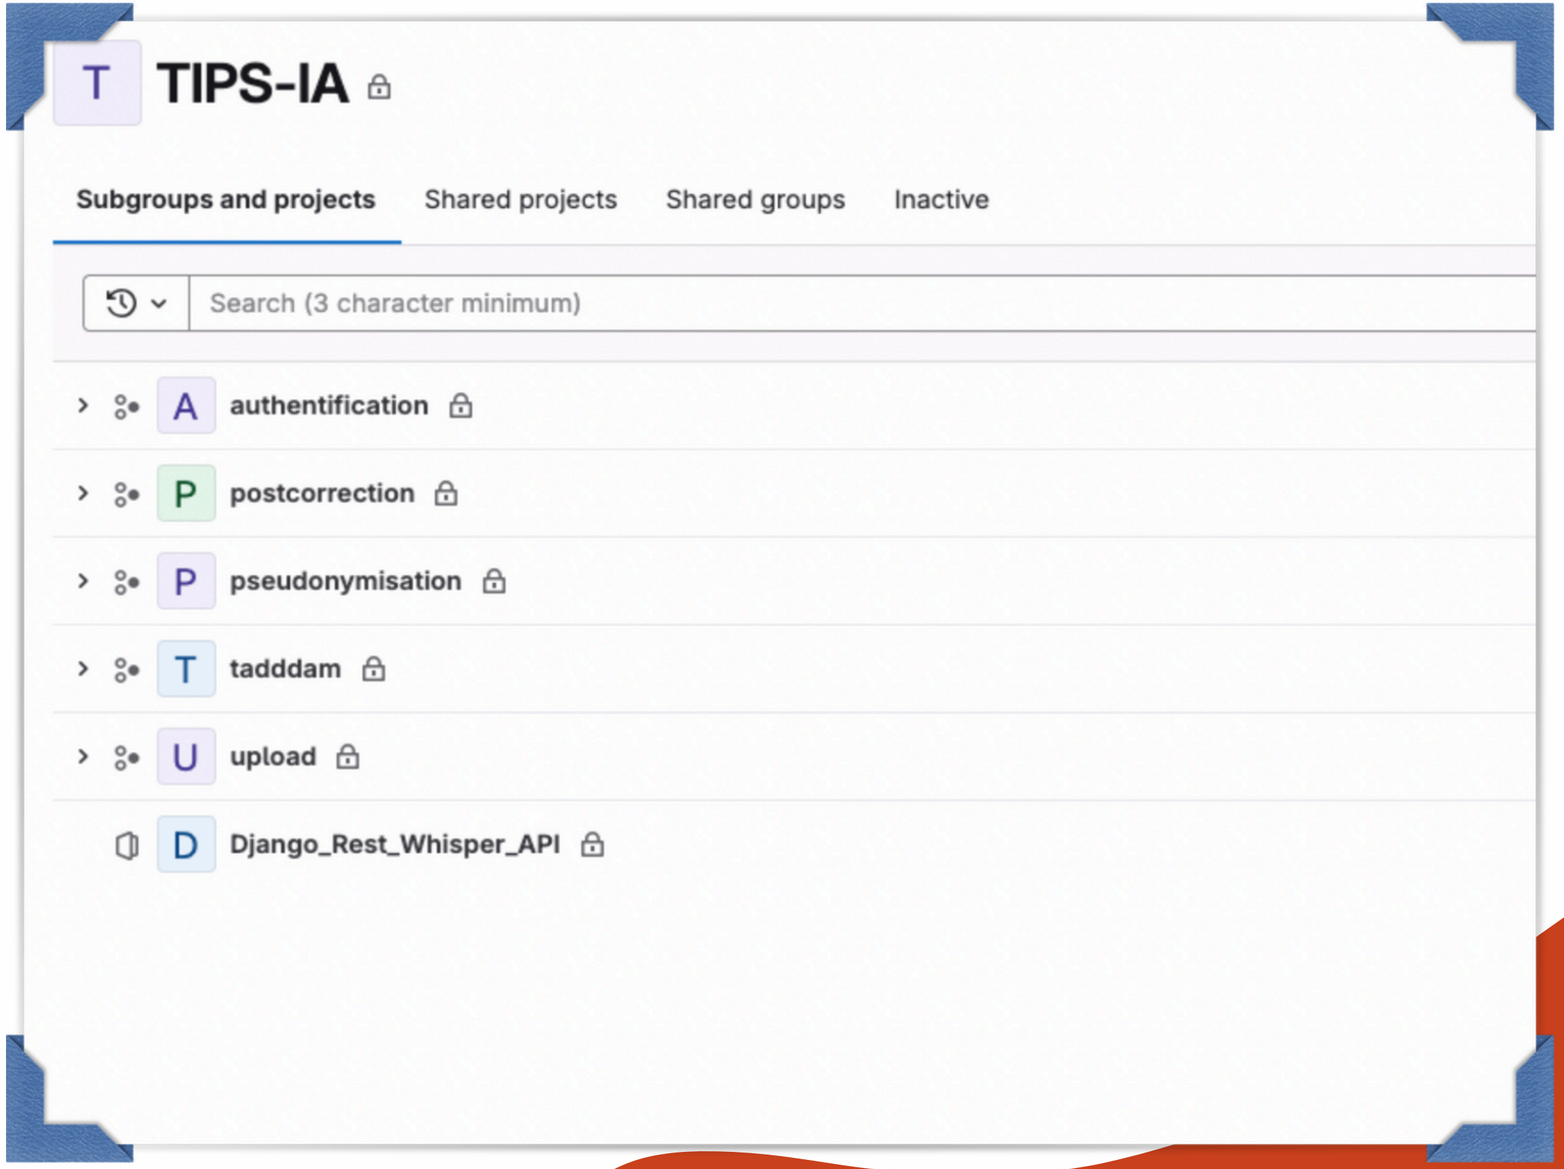
- Traitement de données textuelles
- Outils d’annotation
- Pseudonymisation de textes
- Pseudonymisation des PCS (Professions et Catégories Socioprofessionnelles)
- Conférences et valorisation
- Réflexivité sur les usages

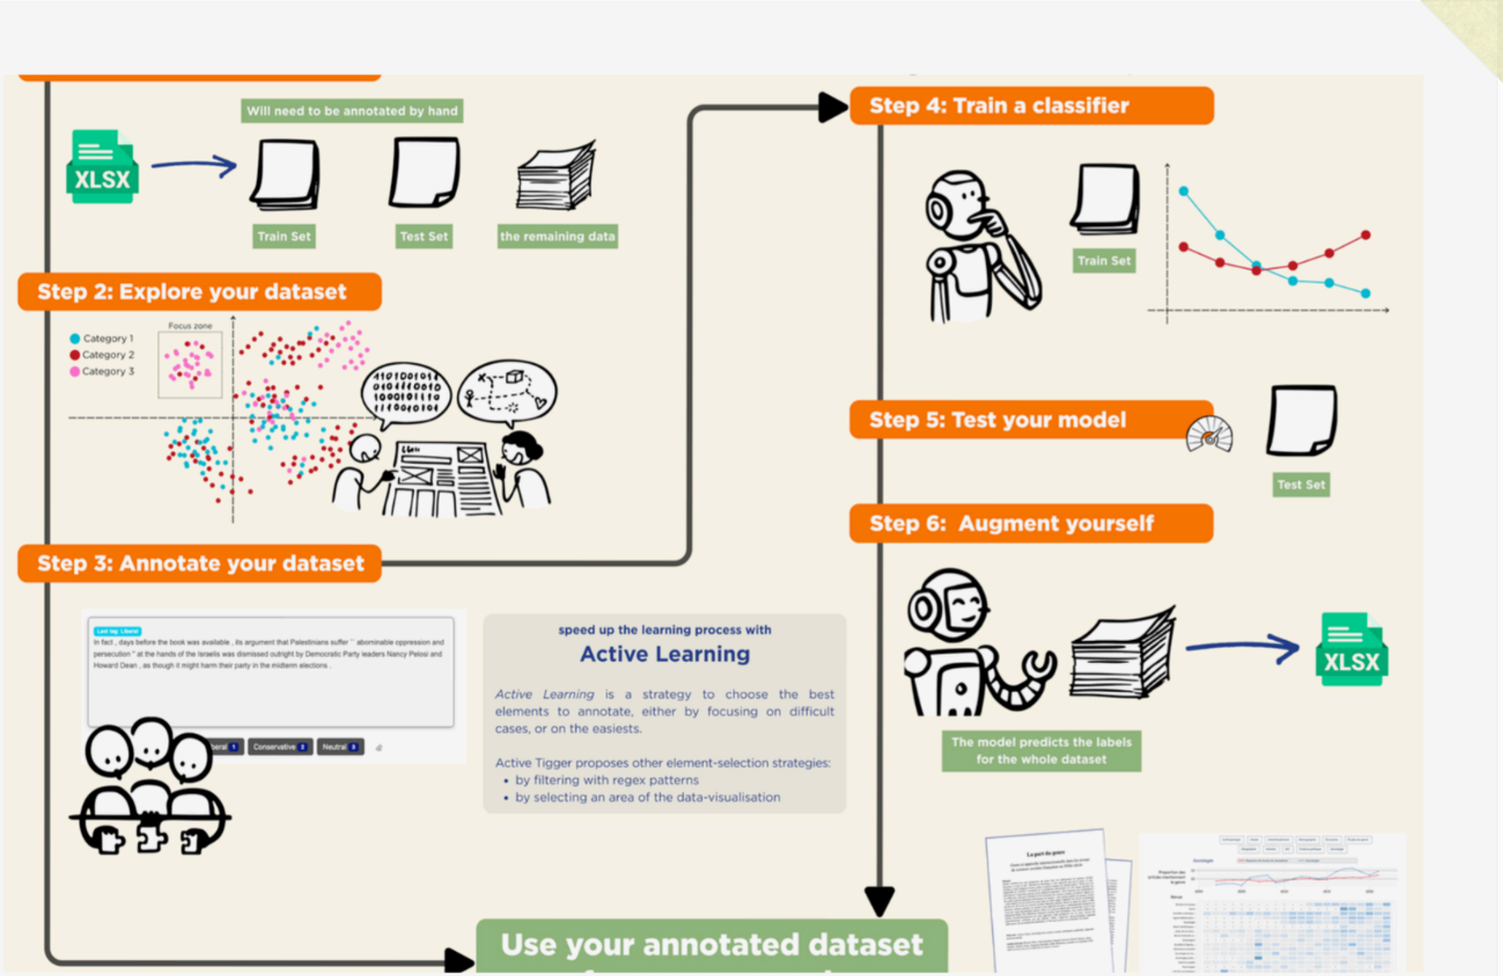
Nous rejoindre et nous écrire : https://groupes.renater.fr/sympa/info/tips-ia

Réalisations de TIPS-IA

L’IA pour coder

https://videos.univ-grenoble-alpes.fr/recherche/ia4dev-2025-lintelligence-artificielle-au-service-du-developpement-logiciel/video/33162-utilisation-de-lia-pour-coder-retour-dexperience/





Active Tigger

D’autres outils

- Large littérature sur les solutions facilitées par IA.
- Souvent des solutions propriétaires dont nous ne connaissons pas les tenants et aboutissants.
- Nous en parlerons peu.

Quelque chose cloche ?

Détecter des liens faibles entre concepts pour générer des idées originales

NotebookLM : https://notebooklm.google/

Structuration parallèle de deux corpus issus de domaines éloignés pour identifier concepts clés, tensions, logiques internes.

Napkin : https://www.napkin.ai/

Capture d'intuitions et de fragments d'idées, génération spontanée de connexions inattendues entre éléments distants.

Gemini (mode créatif) : https://gemini.google.com/app

Exploration d'analogies, formulation d'hypothèses interdomaines, création de scénarios de recherche ou d'ateliers innovants.

Whimsical https://whimsical.com/ (ou Miro) : Pensée divergente

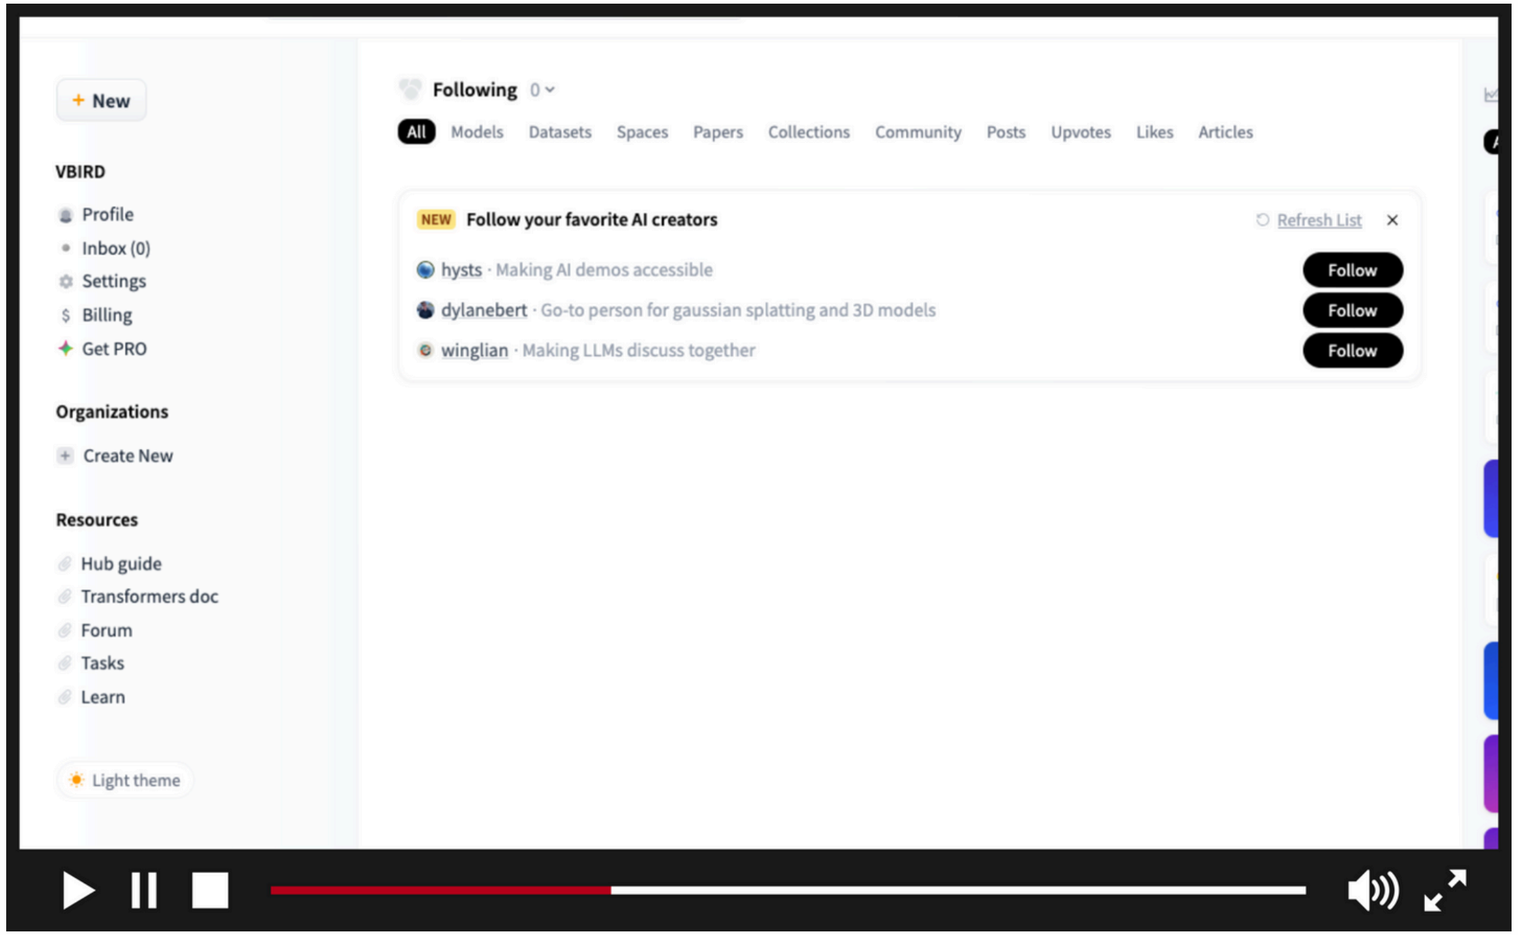
Transforme les connexions faibles en idées originales applicables à vos projets concrets.

Source : Webinaire CEDRE

Aller plus loin

- Les outils proposés par HumaNum notamment sont puissants, mais assez peu paramétrables.
- Il existe une plateforme qui répertorie la plupart des modèles d’IA disponibles.
- Il est assez facile d’y accéder pour faire tourner des modèles, mais il faut quelques bases en Python.

HuggingFace



Plateforme d'IA open-source associée à une communauté très large.

Les chercheur.euse.s et développeur.euse.s peuvent y partager et télécharger des modèles, des outils, des ressources pour des projets en IA.

Contrairement à beaucoup d'outils et projets IA, la plateforme est libre et open-source.

HuggingFace

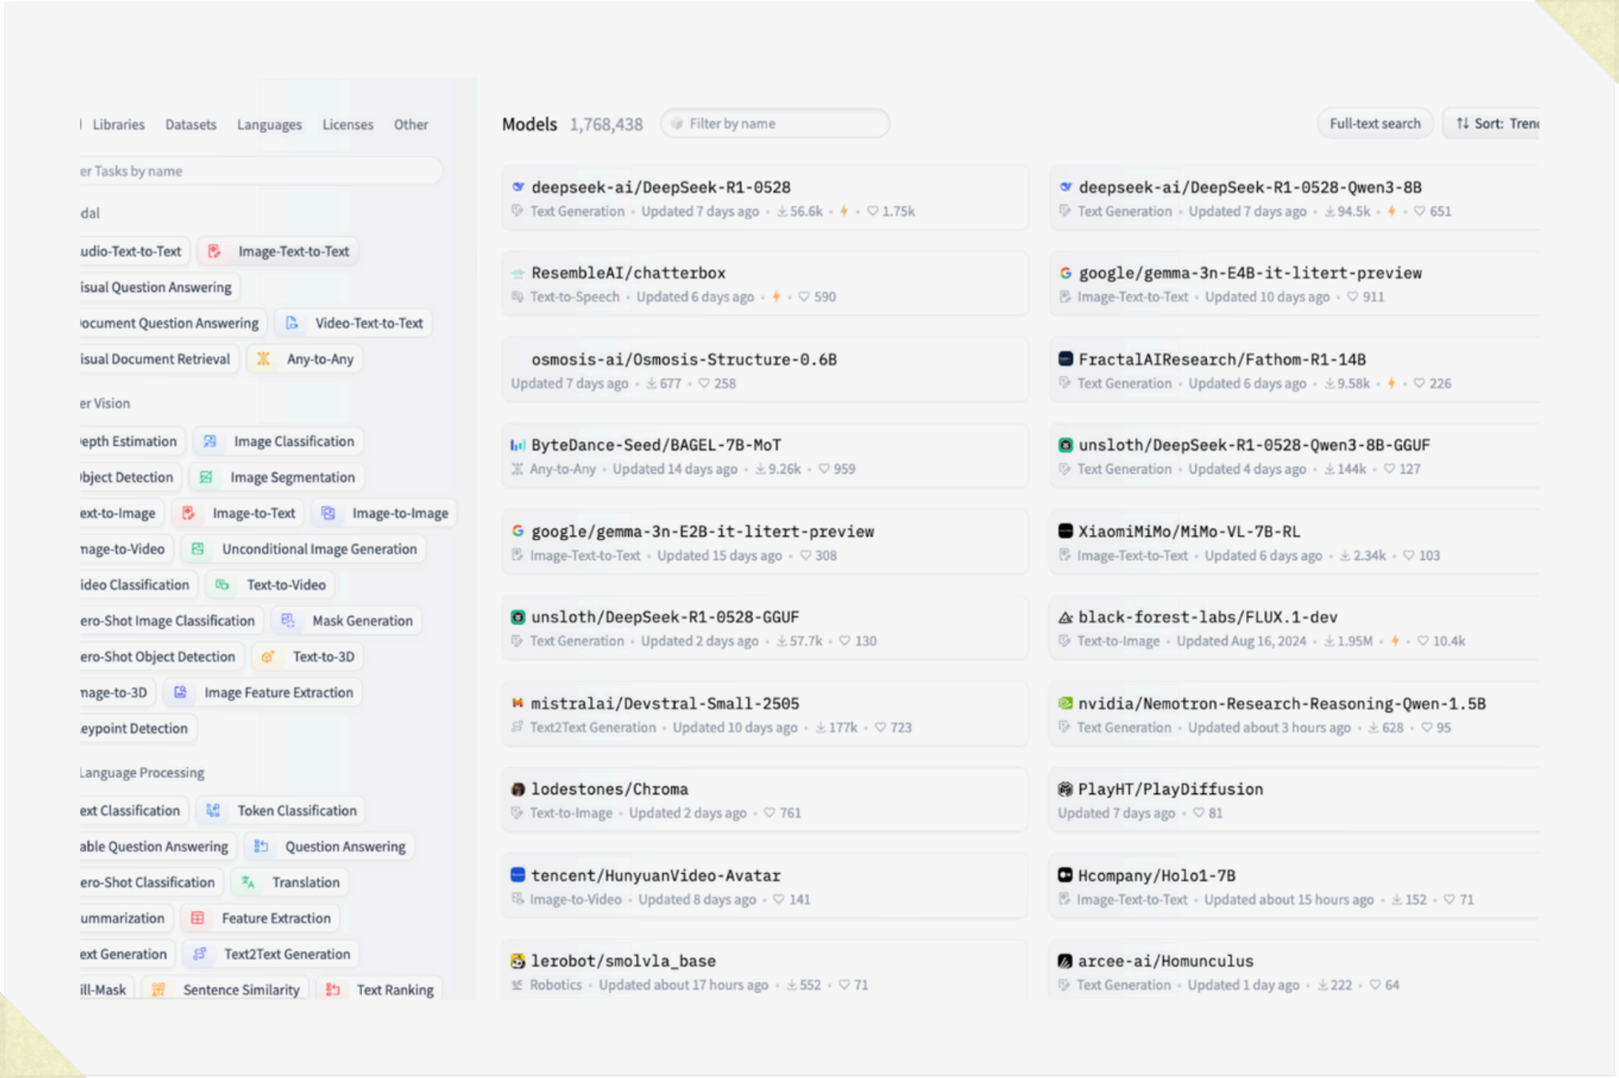


La désignation open source /ˈoʊpən sɔɹs/[1], ou code source ouvert[2], s'applique aux logiciels (et s'étend maintenant aux œuvres de l'esprit) dont la licence respecte des critères précisément établis par l'Open Source Initiative, c'est-à-dire les possibilités de libre redistribution, d'accès au code source et de création de travaux dérivés.

Mis à la disposition du grand public, ce code source est généralement le résultat d'une collaboration entre programmeurs.

Wikipedia

Un supermarché de modèles



Huggingface

Un exemple d’utilisation

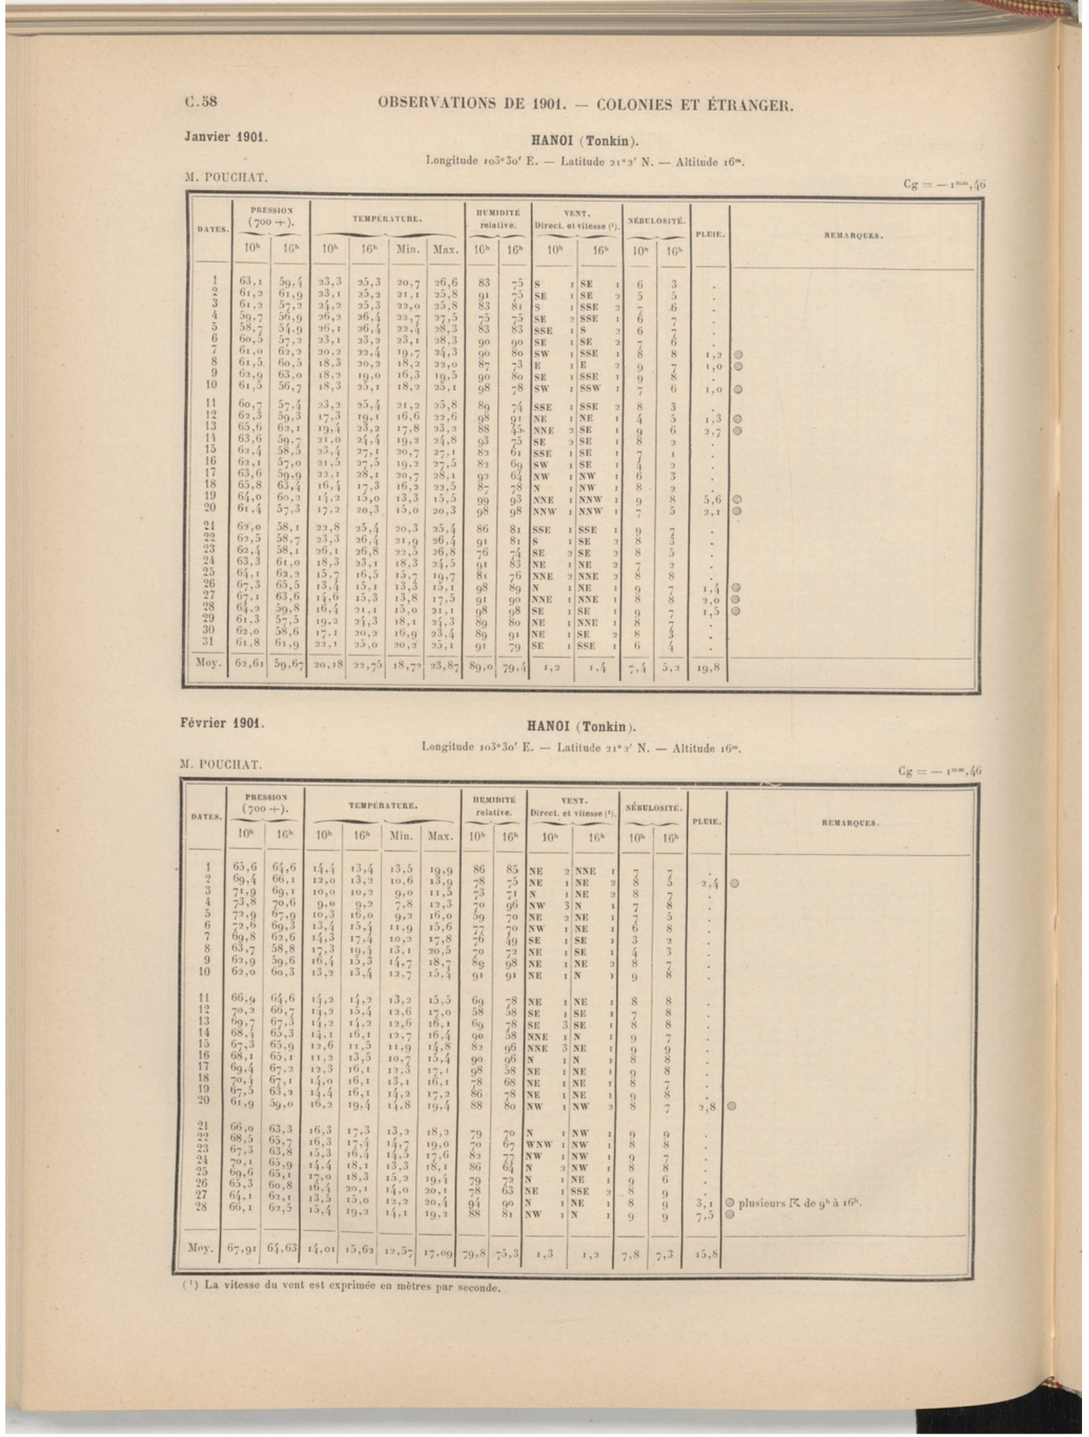
- Des fichiers .pdf avec une OCRisation compliquée…
- L’outil d’HumaNum n’a pas permis d’obtenir satisfaction
- Il m’a donc fallu explorer un autre modèle, et paramétrer les sorties

Moduler l’outil

En utilisant un outil d’OCR via une bibliothèque Python, on est beaucoup plus à même de paramétrer son fonctionnement et l’adapter au cas particulier.

Un cas pratique

Un tableau numérisé, difficilement traduisible par un OCR classique.



C.58 OBSERVATIONS DE 1901. — COLONIES ET ÉTRANGER.

Janvier 1901. **HANOI (Tonkin).**

Longitude 103°30′ E. — Latitude 21°2′ N. — Altitude 16m.

M. POUCHAT. Cg = — 1mm,46

DATES.	PRESSION (700 +). 10h	16h	TEMPÉRATURE. 10h	16h	Min.	Max.	HUMIDITÉ relative. 10h	16h	VENT. Direct. et vitesse (1). 10h	16h	NÉBULOSITÉ. 10h	16h	PLUIE.	REMARQUES.
1	63,1	59,4	23,3	25,3	20,7	26,6	83	75	S 1	SE 1	6	3	.	
2	61,2	61,9	23,1	25,2	21,1	25,8	91	75	SE 1	SE 2	5	5	.	
3	61,2	57,7	24,2	25,3	23,0	25,8	83	81	S 1	SSE 2	7	6	.	
4	59,7	56,9	26,2	26,4	23,7	27,5	75	75	SE 2	SSE 1	6	7	.	
5	58,7	54,9	26,1	26,4	22,4	28,3	83	83	SSE 1	S 2	6	7	.	
6	60,5	57,2	23,1	23,2	23,1	28,3	90	90	SE 1	SE 2	7	6	.	
7	61,0	62,3	20,2	22,4	19,7	24,3	90	80	SW 1	SSE 1	8	8	1,2	●
8	61,3	60,3	18,3	20,2	18,2	23,0	87	73	E 1	E 2	9	7	1,0	●
9	63,9	63,0	18,2	19,0	16,3	19,3	90	80	SE 1	SSE 1	9	8	.	
10	61,5	56,7	18,3	23,1	18,2	23,1	98	78	SW 1	SSW 1	7	6	1,0	●
11	60,7	57,4	23,2	25,4	21,2	25,8	89	74	SSE 1	SSE 2	8	3	.	
12	62,3	59,3	17,3	19,1	16,6	23,6	98	91	NE 1	NE 1	4	5	1,3	●
13	65,6	62,1	19,4	23,2	17,8	23,2	88	45	NNE 2	SE 1	9	6	2,7	●
14	63,6	59,7	21,0	24,4	19,2	24,8	93	75	SE 2	SE 1	8	2	.	
15	63,4	58,5	23,4	27,1	20,7	27,1	82	61	SSE 1	SE 1	7	1	.	
16	62,1	57,0	21,5	27,5	19,2	27,5	82	69	SW 1	SE 1	4	2	.	
17	63,6	59,9	22,1	28,1	20,7	28,1	92	63	NW 1	NW 1	6	3	.	
18	65,8	63,4	16,4	17,3	16,2	22,5	87	78	N 1	NW 1	8	2	.	
19	64,9	60,2	14,2	15,0	13,3	15,5	99	93	NNE 1	NNW 1	9	8	5,6	●
20	61,4	57,3	17,2	20,3	15,0	20,3	98	98	NNW 1	NNW 1	7	5	2,1	●
21	63,6	58,1	22,8	25,4	20,3	25,4	86	81	SSE 1	SSE 1	9	7	.	
22	62,5	58,7	23,3	26,4	21,9	26,4	91	81	S 1	SE 2	8	3	.	
23	62,4	58,1	26,1	26,8	22,3	26,8	76	74	SE 2	SE 2	8	5	.	
24	63,3	61,0	18,3	23,1	18,3	24,5	91	83	NE 1	NE 2	7	2	.	
25	64,1	63,2	15,7	16,5	15,7	19,7	81	76	NNE 2	NNE 2	8	8	.	
26	67,3	65,5	13,4	15,1	13,3	13,1	98	89	N 1	NE 1	9	7	1,4	●
27	67,1	63,6	14,6	15,3	13,8	17,5	91	90	NNE 1	NNE 1	8	8	2,0	●
28	64,2	59,8	16,4	21,1	15,0	21,1	98	98	SE 1	SE 1	9	7	1,5	●
29	61,3	57,5	19,2	24,3	18,1	24,3	89	80	NE 1	NNE 1	8	7	.	
30	62,0	58,6	17,1	20,2	16,9	23,4	89	91	NE 1	SE 2	8	3/4	.	
31	61,8	61,9	22,1	25,0	20,2	25,1	91	79	SE 1	SSE 1	6	4	.	
Moy.	63,61	59,67	20,18	22,75	18,77	23,87	89,0	79,4	1,2	1,4	7,4	5,2	19,8	

Février 1901. **HANOI (Tonkin).**

Longitude 103°30′ E. — Latitude 21°2′ N. — Altitude 16m.

M. POUCHAT. Cg = — 1mm,46

DATES.	PRESSION (700 +). 10h	16h	TEMPÉRATURE. 10h	16h	Min.	Max.	HUMIDITÉ relative. 10h	16h	VENT. Direct. et vitesse (1). 10h	16h	NÉBULOSITÉ. 10h	16h	PLUIE.	REMARQUES.
1	65,6	64,6	14,4	13,4	13,5	19,9	86	85	NE 2	NNE 1	7	7	.	
2	69,4	66,1	12,0	13,3	10,6	13,9	78	75	NE 1	NE 2	8	5	2,4	●
3	71,9	69,1	10,0	10,2	9,0	11,3	73	71	N 1	NE 2	8	8	.	
4	73,8	70,6	9,0	9,2	7,8	12,3	70	96	NW 3	N 1	7	8	.	
5	72,9	67,9	10,3	16,0	9,2	16,0	59	70	NE 2	NE 1	7	5	.	
6	72,6	69,3	13,4	15,4	11,9	15,6	77	70	NW 1	NE 1	6	8	.	
7	69,8	63,6	14,3	17,4	10,2	17,8	76	49	SE 1	SE 1	3	2	.	
8	63,7	58,8	17,3	19,4	13,1	20,5	70	72	NE 1	SE 1	4	3	.	
9	62,9	59,6	16,4	13,3	14,7	18,7	89	98	NE 1	NE 2	8	8	.	
10	62,0	60,3	13,2	13,4	12,7	15,4	91	91	NE 1	N 1	9	8	.	
11	66,9	64,6	14,2	14,2	13,2	15,5	69	78	NE 1	NE 1	8	8	.	
12	70,2	66,7	14,2	13,4	12,6	17,0	58	58	SE 1	SE 1	7	8	.	
13	69,7	67,3	14,2	14,2	12,6	16,1	69	78	SE 3	SE 1	8	8	.	
14	68,4	65,3	14,1	16,1	12,7	16,4	90	58	NNE 1	N 1	9	7	.	
15	67,3	65,9	13,6	11,5	11,9	14,8	82	96	NNE 3	NE 1	9	9	.	
16	68,1	65,1	11,2	13,5	10,7	15,4	90	96	N 1	N 1	8	8	.	
17	69,4	67,2	12,3	16,1	12,3	17,1	98	58	NE 1	NE 1	8	8	.	
18	70,4	67,1	14,0	16,1	13,1	16,1	78	68	NE 1	NE 1	8	7	.	
19	67,5	63,2	14,4	16,1	14,2	17,2	86	78	NE 1	NE 1	9	8	.	
20	61,9	59,0	16,2	19,4	14,8	19,4	88	80	NW 1	NW 2	8	7	2,8	●
21	66,0	63,3	16,3	17,3	13,2	18,2	79	70	N 1	NW 1	9	9	.	
22	68,5	65,7	16,3	17,4	14,7	19,0	70	67	WNW 1	NW 1	8	8	.	
23	67,3	63,8	15,3	16,4	14,5	17,6	82	77	NW 1	NW 1	9	7	.	
24	70,1	65,9	14,4	18,1	13,3	18,1	86	64	N 2	NW 1	8	8	.	
25	69,6	65,1	17,0	18,3	15,2	19,4	79	72	N 1	NE 1	9	6	.	
26	65,3	60,8	16,4	20,1	14,0	20,1	78	63	NE 1	SSE 3	8	9	.	
27	64,1	62,1	13,3	15,0	12,2	20,4	94	90	N 1	NE 1	8	9	3,1	● plusieurs ☈ de 9h à 16h.
28	66,1	62,5	15,4	19,2	14,1	19,2	88	81	NW 1	N 1	9	9	7,5	●
Moy.	67,91	64,63	14,01	15,62	12,57	17,09	79,8	75,3	1,3	1,2	7,8	7,3	15,8	

(1) La vitesse du vent est exprimée en mètres par seconde.

Source gallica.bnf.fr / Bibliothèque de Météo-France

Après consultation de la clinique données de l'ISDM

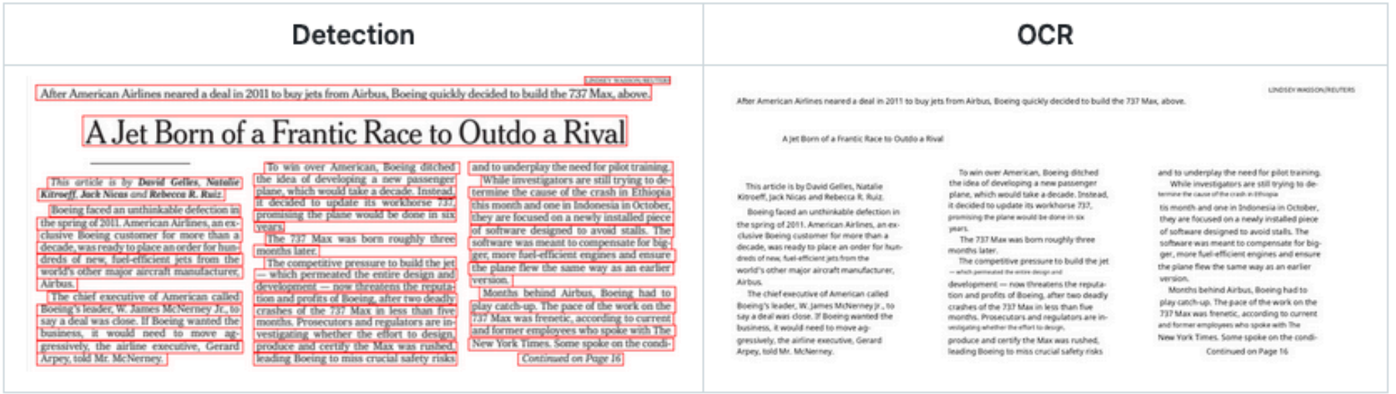
https://github.com/VikParuchuri/surya

Surya

Surya is a document OCR toolkit that does:

- OCR in 90+ languages that benchmarks favorably vs cloud services
- Line-level text detection in any language
- Layout analysis (table, image, header, etc detection)
- Reading order detection
- Table recognition (detecting rows/columns)
- LaTeX OCR

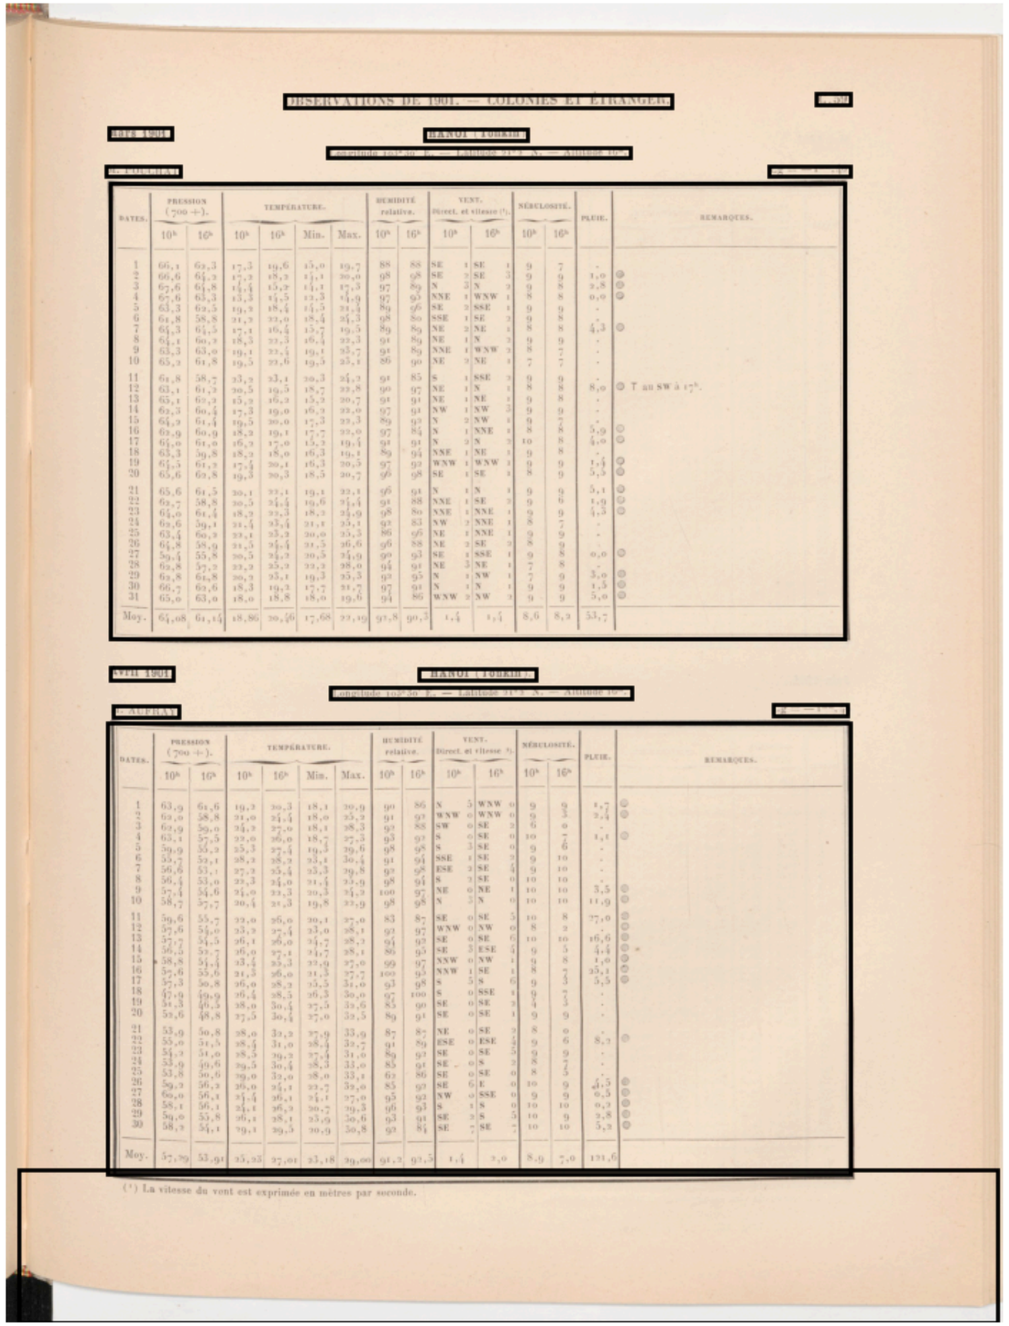
It works on a range of documents (see usage and benchmarks for more details).





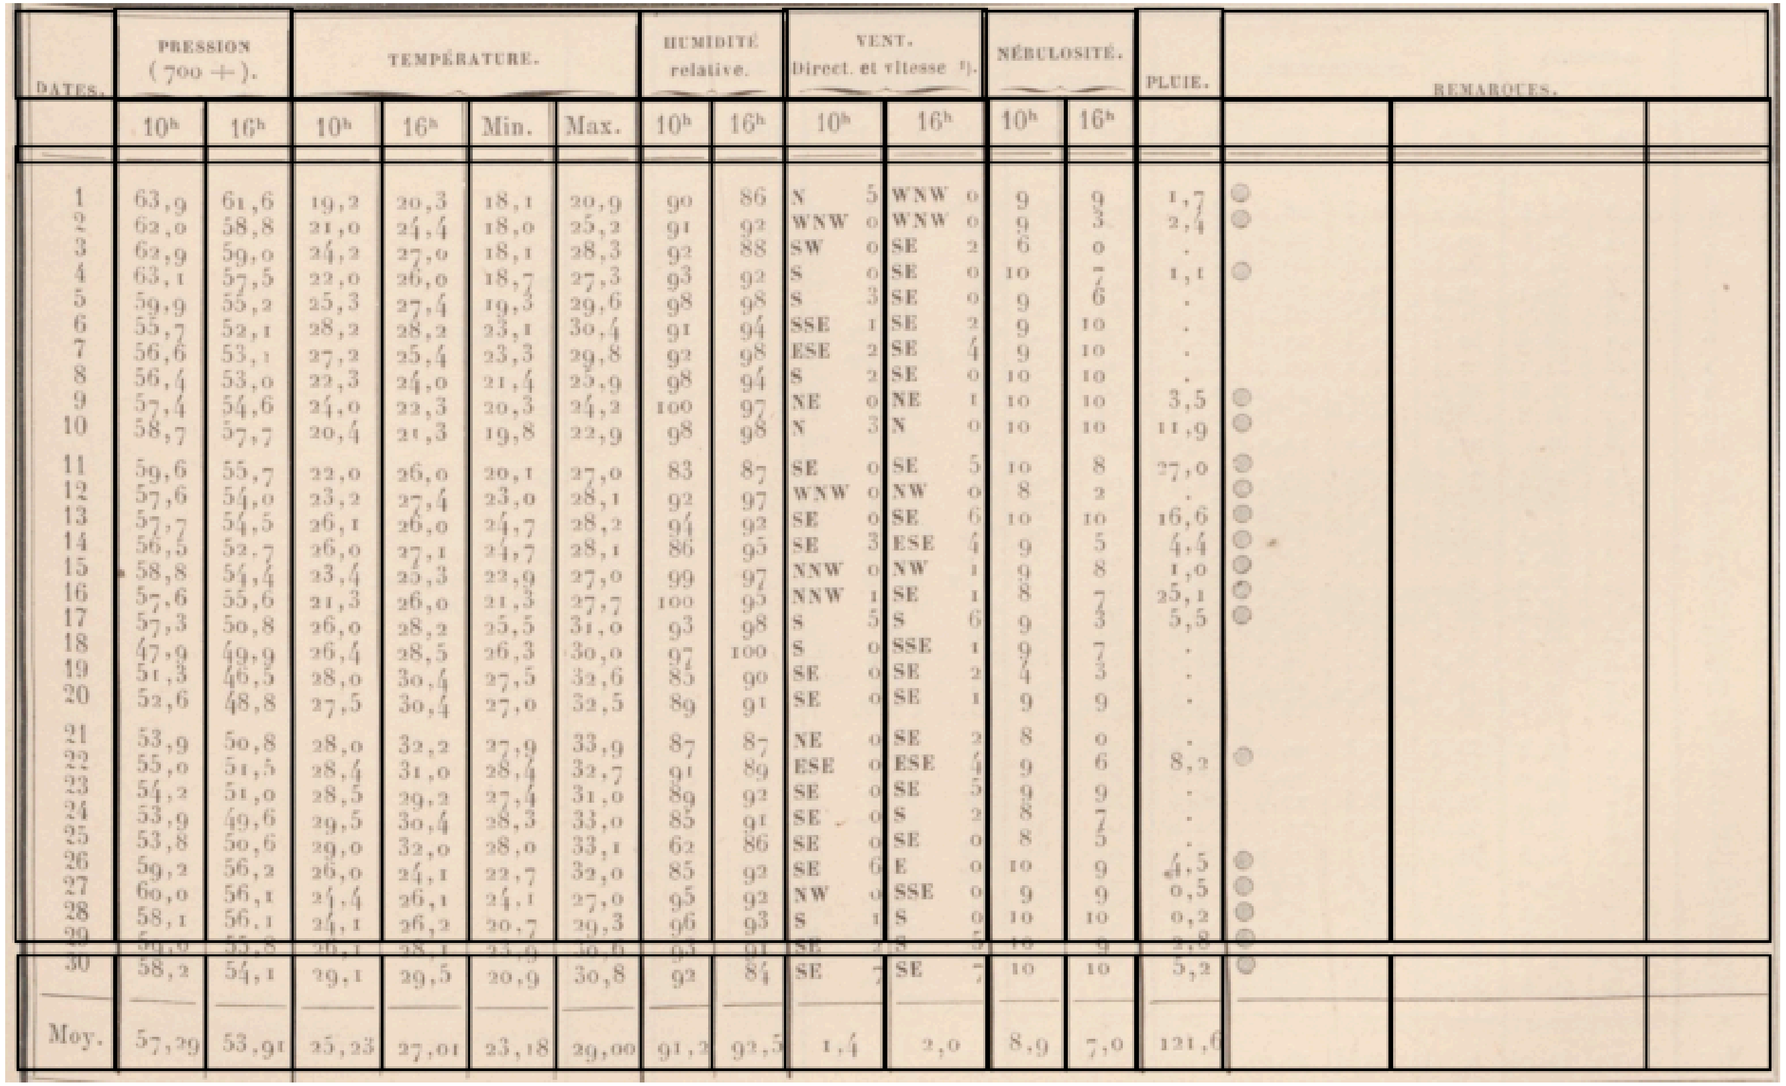
Intérêt de l’outil

Une première étape pour reconnaître la mise en page du fichier et isoler les tableaux.



Intérêt de l’outil

On sélectionne ensuite le tableau pertinent et on visualise les différentes cases.



DATES.	PRESSION (700 +).		TEMPÉRATURE.				HUMIDITÉ relative.		VENT. Direct. et vitesse [1].		NÉBULOSITÉ.		PLUIE.	REMARQUES.		
	10h	16h	10h	16h	Min.	Max.	10h	16h	10h	16h	10h	16h				
1	63,9	61,6	19,2	20,3	18,1	20,9	90	86	N 5	WNW 0	9	9	1,7			
2	62,0	58,8	21,0	24,4	18,0	25,2	91	92	WNW 0	WNW 0	9	3	2,4			
3	62,9	59,0	24,2	27,0	18,1	28,3	92	88	SW 0	SE 2	6	0	.			
4	63,1	57,5	22,0	26,0	18,7	27,3	93	92	S 0	SE 0	10	7	1,1			
5	59,9	55,2	25,3	27,4	19,3	29,6	98	98	S 3	SE 0	9	6	.			
6	55,7	52,1	28,2	28,2	23,1	30,4	91	94	SSE 1	SE 2	9	10	.			
7	56,6	53,1	27,2	25,4	23,3	29,8	92	98	ESE 2	SE 4	9	10	.			
8	56,4	53,0	22,3	24,0	21,4	25,9	98	94	S 2	SE 0	10	10	.			
9	57,4	54,6	24,0	22,3	20,3	24,2	100	97	NE 0	NE 1	10	10	3,5			
10	58,7	57,7	20,4	21,3	19,8	22,9	98	98	N 3	N 0	10	10	11,9			
11	59,6	55,7	22,0	26,0	20,1	27,0	83	87	SE 0	SE 5	10	8	27,0			
12	57,6	54,0	23,2	27,4	23,0	28,1	92	97	WNW 0	NW 0	8	2	.			
13	57,7	54,5	26,1	26,0	24,7	28,2	94	92	SE 0	SE 6	10	10	16,6			
14	56,5	52,7	26,0	27,1	24,7	28,1	86	95	SE 3	ESE 4	9	5	4,4			
15	58,8	54,4	23,4	25,3	22,9	27,0	99	97	NNW 0	NW 1	9	8	1,0			
16	57,6	55,6	21,3	26,0	21,3	27,7	100	93	NNW 1	SE 1	8	7	25,1			
17	57,3	50,8	26,0	28,2	25,5	31,0	93	98	S 5	S 6	9	3	5,5			
18	47,9	49,9	26,4	28,5	26,3	30,0	97	100	S 0	SSE 1	9	7	.			
19	51,3	46,5	28,0	30,4	27,5	32,6	85	90	SE 0	SE 2	4	3	.			
20	52,6	48,8	27,5	30,4	27,0	32,5	89	91	SE 0	SE 1	9	9	.			
21	53,9	50,8	28,0	32,2	27,9	33,9	87	87	NE 0	SE 2	8	0	.			
22	55,0	51,5	28,4	31,0	28,4	32,7	91	89	ESE 0	ESE 4	9	6	8,2			
23	54,2	51,0	28,5	29,2	27,4	31,0	89	92	SE 0	SE 5	9	9	.			
24	53,9	49,6	29,5	30,4	28,3	33,0	85	91	SE 0	S 2	8	7	.			
25	53,8	50,6	29,0	32,0	28,0	33,1	62	86	SE 0	SE 0	8	5	.			
26	59,2	56,2	26,0	24,1	22,7	32,0	85	92	SE 6	E 0	10	9	4,5			
27	60,0	56,1	24,4	26,1	24,1	27,0	95	92	NW 0	SSE 0	9	9	0,5			
28	58,1	56,1	24,1	26,2	20,7	29,3	96	93	S 1	S 0	10	10	0,2			
29	60,0	55,8	26,1	28,1	23,9	30,6	93	91	SE 2	S 5	10	9	2,8			
30	58,2	54,1	29,1	29,5	20,9	30,8	92	84	SE 7	SE 7	10	10	5,2			
Moy.	57,29	53,91	25,23	27,01	23,18	29,00	91,2	92,5	1,4	2,0	8,9	7,0	121,6			

Intérêt de l’outil

Cellule par cellule, le modèle d’OCR peut ensuite récupérer l’information.

Les cellules étant codées et répertoriées, on peut reconstituer le tableau automatiquement.

col_id		0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
row_id	unique_id															
0	0	NaN	PRESSION	NaN	TEMPERATURE.	NaN	NaN	NaN	HUMIDITE	NaN	VIENT .	NaN	NEBULOSITE.	NaN	PLUIE.	NaN
	1	NaN	(700 +).	NaN	NaN	NaN	NaN	NaN	relative.	NaN	Direct. et vitesse 1).	NaN	NaN	NaN	NaN	NaN
1	0	NaN	10h	16h	10h	16h	Min.	Max.	10h	16h	10h	16h	10h	16h	NaN	NaN
2	0	1	63,9	61,6	19,2	20.3	18,1	20,9	go	86	N	WNW	9	9	I,7	C
	1	2	62,0	58,8	21,0	24,4	18.0	23,2	gr	92	é	O	G	O	2,4	é
	2	3	62,9	59,0	24,2	27,0	18, I	28.3	93	88	S	WNW	6	t	I, I	e
	3	4	63, I	27,5	22,0	26,0	18,7	27,3	des	92	é	O	IO	6	.	()
	4	5	59,9	00,2	25,3	27,4	19,5	29,6	gr	98	NE	SE	9	IO	.	es
	5	6	55,7	52,I	28,2	28,2	25, I	30,4	92	94	N	2	9	IO	.	es
	6	7	56,6	53,1	27,2	25,4	23,3	29,8	98	98	I S	SE	9	IO	.	e
	7	8	56,4	53,0	22,3	24,0	21,4	20,9	I 00	94	SE	e	IO	IO	3,5	e
	8	9	57,4	54,6	24,0	22,3	20,3	24,2	98	97	NaN	SE	IO	IO	II,9	O
	9	10	58,7	37,7	20,4	21,3	19,8	22,9	83	98	NaN	SE	IO	8	27,0	[illegible]
	10	11	29,6	55,7	22,0	26.0	20, I	27,0	92	87	NaN	e I	IO	2	16,6	es
	11	12	07,6	54,0	23,2	27,4	23,0	28, I	96	97	NaN	SE	8	IO	4,4	O
	12	13	07 : 7	54,5	26, I	26,0	24,7	28,2	99	92	NaN	SE	IO	5	I,0	e
	13	1 4	56,5	52.7	26.0	27, I	24,7	28, I	I OO	go	NaN	NE	9	8	25,1	es
	14	15	58,8	54,4	23,4	25,3	22,9	27,0	93	97	NaN	N	9	7	5,5	es
	15	16	57,6	35,6	21,3	26,0	21,5	27,7	97	95	NaN	SE	8	7	.	0
	16	17	07,3	50,8	26.0	28,2	23,3	01,0	89	98	NaN	SE	9	9	8,2	NaN
	17	18	47,9	49,9	26,4	28,3	26,3	30.0	87	I OO	NaN	ESE	9	O	4,5	NaN

En revanche, il faut un petit peu coder…

- Si vous souhaitez vous lancer, plusieurs formations sont disponibles (IRD, voir bibliographie).

- Vous pouvez également vous rapprocher du PolDoR et remplir le formulaire de contact disponible sur **cette page.**



Bibliographie / Sitographie

- **Cours et webinaires**
  - https://www.cnil.fr/fr/revoir-le-webinaire-comment-deployer-un-systeme-dia-generative-les-premieres-preconisations
  - https://www.fidle.cnrs.fr/w3/whatsup.html
  - https://nealcaren.github.io/python-tutorials/
- **Sites et articles**
  - https://sebastien-sime.medium.com/introduction-%C3%A0-lutilisation-des-transformers-avec-hugging-face-9e13a92c8931
  - https://www.cnil.fr/fr/intelligence-artificielle/glossaire-ia
  - https://www.cnil.fr/fr/rgpd-de-quoi-parle-t-on
- **Ouvrages**
  - Daniel Andler, *Intelligence artificielle, intelligence humaine : la double énigme*, Paris, Gallimard, 2023, 432 p.
  - Émilien Schultz, Matthias Bussonnier, *Python pour les SHS. Introduction à la programmation pour le traitement de données*, Rennes, Presses universitaires de Rennes, col. « Pratique de la statistique », 2021, 329 p. https://pur-editions.fr/product/7857/python-pour-les-shs
- **Ressources autres**
  - https://documentation.huma-num.fr/infrastructure-IA/
  - https://gitlab.in2p3.fr/isdm_formation
  - https://agepouvoir.hypotheses.org/494

Merci pour votre attention !

PolDoR
Pôle Données de la Recherche

MSHSUD
Maison des Sciences et des Humanités